

IDMSpHGiAGR

Identyfikacja DMS pomiędzy HG i AGR

Grupa 4

2026-06-24

Table of contents

1 IDMSpHGiAGR - Identyfikacja DMS pomiędzy HG i AGR	1
1.1 Wstęp	1
1.1.1 Abstrakt / streszczenie	1
1.1.2 Cel naukowy	2
1.1.3 Aktualny stan wiedzy	2
1.2 Metodologia	5
1.2.1 Kohorty i liczba próbek	5
1.2.2 Mapy metylacyjne dla populacji współczesnych	5
1.2.3 Mapy metylacyjne dla populacji kopalnych	7
1.2.4 Symulacja DMS	11
1.2.5 Analiza DMS dla populacji współczesnych	12
1.2.6 Analiza DMS dla populacji kopalnych	13
1.2.7 Metoda statystyczna do porównywania populacji.	16
1.3 Oczekiwane wyniki	17
1.3.1 Cechy charakterystyczne	17
1.3.2 Wpływ na tezy historyczne	17
1.3.3 Możliwe problemy	17

1 IDMSpHGiAGR - Identyfikacja DMS pomiędzy HG i AGR

1.1 Wstęp

1.1.1 Abstrakt / streszczenie

Projekt IDMSpHGiAGR ma na celu opracowanie nowej, niezależnej od artefaktów archeologicznych metody klasyfikacji prehistorycznych strategii utrzymania (łowców-zbieraczy [HG] vs. społeczności rolniczych [AGR]) na podstawie analizy porównawczej map metylacji DNA.

Do zdefiniowania referencyjnych sygnatur epigenetycznych wykorzystamy metodologię użytą w badaniu [1]. W oparciu o ten model wyodrębniamy trzy abstrakcyjne klasy populacyjne:

- grupę agrarną osiadłą,
- grupę agrarną niedawno poddaną transformacji środowiskowej,
- tradycyjną grupę łowiecko-zbieracką

Zastosowanie analizy *cis-meQTL* umożliwi nam odseparowanie adaptacji środowiskowej od tej determinowanej przez uwarunkowania genetyczne. Jest to kluczowe do uzyskania informacji o modyfikacjach związanych ze zmianami środowiskowymi.

Uzyskane sygnatury zostaną zwalidowane na populacjach antycznych o jednoznacznych strategiach utrzymania, to jest: głębokim neolitycznym tle (dawniej niż 20 tys. lat p.n.e. – pewne HG) oraz utrwalonych społecznościach rolniczych (do 2 tys. lat p.n.e. – pewne AGR).

Pozycje różnicowo zmetylowane (DMS), wykazujące istotną statystycznie zależność ze zbiorami walidacyjnymi, zostaną zdefiniowane jako zestaw stabilnych ewolucyjnie markerów epigenetycznych (#TODO - jakiś skrót tego).

Mając już zestaw stabilnych ewolucyjnie markerów, użyjemy dedykowanego modelu probabilistycznego do zbadanych profili genetycznych w celu otrzymania danych, które dadzą nam nową perspektywę na sposób funkcjonowania populacji mezolitycznych, takich jak Çatalhöyük.

1.1.2 Cel naukowy

Celem naukowym jest skonstruowanie nowej metody epigenetycznej umożliwiającej klasyfikację populacji prehistorycznych jako *hunter-gatherers* (HG) lub rolniczo-miejskich (AGR), niezależnej od artefaktów archeologicznych.

Metoda wykorzystywałaby scharakteryzowane modyfikacje epigenetyczne we współczesnych populacjach autochtonicznych HG i AGR zestawionych z ludnościami antycznymi.

1.1.3 Aktualny stan wiedzy

1.1.3.1 Metody rekonstrukcji map metylacji

1.1.3.1.1 Wykorzystane zjawisko - deaminacja cytozyn

Rekonstrukcja map metylacji z kopalnego DNA (aDNA) opiera się na zjawisku deaminacji cytozyn – dominującym procesie chemicznego rozkładu aDNA [2]. Niemetylowana cytozyna deaminuje do uracylu ($C \rightarrow U$), natomiast metylowana 5-metylocytozyna deaminuje do tyminy ($5mC \rightarrow T$). Tempo deaminacji jest silnie zależne od struktury fragmentu: w jednoniciowych cząsteczkach na końcach fragmentów sięga kilkudziesięciu procent, podczas gdy w częściach dwuniciowych wynosi około 1% lub mniej; uśredniony wskaźnik deaminacji fragmentu mieści się zwykle w przedziale 1–3%. Protokoły przygotowania bibliotek z (częściowym lub pełnym) traktowaniem USER / UDG (*Uracil-Specific Excision Reagent*) usuwają uracyl, ale nie naruszają tymin. Dzięki temu udział tymin na wyspach CpG (gdzie cytozyna jest metylowana w genomie ssaków), zwany wskaźnikiem $C \rightarrow T$, może służyć jako estymator przedśmiertnego poziomu metylacji.

Dla pozycji i definiuje się wskaźnik:

$$C \rightarrow T(i) = \frac{t_i}{t_i + c_i}$$

Gdzie t_i oraz c_i to liczby odczytów z tyminą i cytozyną na danej pozycji. Wyższy wskaźnik odpowiada wyższemu poziomowi metylacji. Ponieważ poziomy metylacji sąsiadujących CpG są silnie skorelowane (ko-metylacja w obrębie regionów rzędu ≈ 2 kpz), estymację wygładza się w przesuwym oknie obejmującym kilka-kilkadziesiąt kolejnych CpG, co radykalnie redukuje błąd standardowy estymatora.

1.1.3.1.2 Metoda oryginalna

Metoda oryginalna [3] dotyczyła pierwszej pełnej rekonstrukcji metylomu neandertalczyka i denisowianina. Wymaga próbek o wysokim pokryciu shotgun ($\geq \approx 15\times$) poddanych traktowaniu USER. Porównanie z metylomami współczesnych ludzi pozwoliło zidentyfikować ≈ 2000 regionów różnicowo zmetylowanych (DMR), w tym istotne zmiany w klastrze *HOXD*, potencjalnie tłumaczące różnice anatomiczne między człowiekiem archaicznym a współczesnym. Ograniczeniem jest jednak dostępność danych: bardzo niewiele próbek aDNA spełnia jednocześnie oba wymagania — wystarczająco wysokie pokrycie oraz przygotowanie biblioteki z traktowaniem USER. W praktyce metodę zastosowano dotąd jedynie do nielicznych okazów (neandertalczyk, denisowianin oraz kilku anatomicznie współczesnych ludzi). ***

1.1.3.1.3 Adaptacja metody do danych o niskim pokryciu (Barouch i in., 2024, NAR)

Zdecydowana większość kopalnych osobników jest sekwencjonowana metodą hybrydizacyjnego wzbogacania (*in-solution capture*), najczęściej z użyciem panelu 1240K ($\approx 1,24$ mln SNP) – sekwencjonowanie tylko niewielkich fragmentów genomu, co daje dane zbyt płytkie do rekonstrukcji metylacji na poziomie pojedynczego osobnika. Autorzy [4] wykorzystują obserwację, że zmienność metylacji wewnątrz populacji jest mniejsza niż między populacjami – populacje mają więc charakterystyczne profile metylacyjne. Zamiast rekonstruować mapę indywidualną, łączą odczyty wielu osobników z tej samej populacji, uzyskując mapę metylacji reprezentatywną dla całej populacji. Kluczowe elementy procedury:

- **Naiwne łączenie (naive pulling)** – proste sumowanie liczników C i T w każdej pozycji CpG ze wszystkich osobników; działa równie dobrze lub lepiej niż wariant „zaawansowany” uwzględniający indywidualne tempa deaminacji (osobnicy z tego samego miejsca i okresu przeszli zbliżone procesy deaminacji).
- **Filtrowanie** – usunięcie domniemyanych duplikatów PCR oraz pozycji CpG o wskaźniku $C \rightarrow T > 0,25$ (prawdopodobnie mutacje, a nie deaminacja).
- **Mapowanie $C \rightarrow T$ na metylację** metodą *histogram matching* – nieliniowe dopasowanie histogramu wskaźników $C \rightarrow T$ do referencyjnego histogramu metylacji we współczesnej kości człowieka (WGBS).
- **Adaptacyjny rozmiar okna** – do 31 kolejnych CpG, dobierany w zależności od efektywnego pokrycia kohorty.
- **Próg jakości** – do wiarygodnej rekonstrukcji potrzebne jest efektywne pokrycie ≥ 12 (najlepiej > 15). Efektywne pokrycie kohorty można z góry oszacować modelem liniowym z liczby osobników i średniej liczby trafień w autosomalne SNP (*single-nucleotide polymorphism*).

Panel 1240K nie jest połączenie dwóch wcześniejszych paneli wzbogacania opracowanych w laboratorium Davida Reicha (Harvard) we współpracy z grupą Nicka Pattersona i innymi. Stąd bywa nazywany „Reich panel”. Jest używany, ponieważ w kopalnych kościach/zębach DNA endogenne (ludzkie) to często $< 1\%$ całego materiału, pozostała część to bakterie glebowe, grzyby, zanieczyszczenia.

Walidacja wykazała, że zrekonstruowane mapy populacyjne odtwarzają oczekiwane cechy biologiczne: hipometylację wysp CpG i promotorów genów *housekeeping*, wysoką metylację elementów Alu, a także najsilniejszą korelację z metylomem osteoblastów (zgodnie ze szkieletowym pochodzeniem aDNA). Detekcję DMR między populacjami przeprowadza się z kontrolą odsetka fałszywych odkryć (FDR – *false discovery rate*) poprzez permutacje etykiet populacyjnych.

1.1.3.1.4 Narzędzia obliczeniowe

Podejście łączenia [4] jest dla nas kluczowe: umożliwia uzyskanie populacyjnych map metylacji z tysięcy już dostępnych, niskopokryciowych próbek 1240K – w tym z populacji bezpośrednio związanych z przejściem HG $\rightarrow$ AGR (np. brytyjski neolit i epoka brązu, kultura pucharów dzwonowatych). Pozwala to prowadzić porównania HG vs. AGR na poziomie populacji, mimo że pojedyncze próbki są zbyt płytkie do klasycznej rekonstrukcji metylomu. Do zautomatyzowanego przetwarzania wykorzystuje się potoki takie jak epiPALEOMIX [5] oraz RoAM [6].

1.1.3.1.5 Cechy epigenetyczne w ludnościach autochtonicznych

#TODO przepisać i przenieść bibliografię Aktualnie wykazano, że istnieje istotna różnica pomiędzy metylacją w populacjach HG i AGR oraz scharakteryzowano, że jest to związane z regulacją immunologiczną oraz rozwojem [1]. Badania jednak były wykonane na komórkach krwi.

1.1.3.1.6 Analizy wykorzystujące metylacje

Aktualnie wykorzystano metylację do scharakteryzowania różnic w mapach metylacyjnych u Neandertalczyków oraz Denisovian [3] oraz zidentyfikowano ERLs związane z głodem i stwierdzono, że w populacjach HG występowały trendy zmian o charakterze adaptacyjnym [7]. Nie zidentyfikowano jednak charakterystycznych czynników epigenetycznych różnicujących grupy HG i AGR na poziomie tkanki kostnej.

1.2 Metodologia

1.2.1 Kohorty i liczba próbek

Szczegółowy podział kohort referencyjnych i walidacyjnych znajduje się w dedykowanym [arkuszu danych](#).

1.2.2 Mapy metylacyjne dla populacji współczesnych

1.2.2.1 Wstęp

Celem tej części metodologii jest wygenerowanie genomowych map metylacji DNA dla współczesnych kohort referencyjnych o jednoznacznym trybie życia - populacji łowiecko-zbierackich (HG) oraz rolniczych (AGR). Mapy te stanowią sygnaturę odniesienia, na podstawie której w dalszej części wyodrębniany jest komponent epigenetyczny związany z trybem życia, oraz punkt kalibracyjny dla map rekonstruowanych z materiału kopalnego.

Zgodnie z założeniem rozszerzenia analizy poza pojedynczą parę populacji afrykańskich [1], profilowanie obejmuje wiele niezależnych par HG/AGR z różnych kontynentów i stref klimatycznych, co zwiększa moc statystyczną oraz pozwala oddzielić uniwersalny efekt trybu życia od lokalnych uwarunkowań genetycznych, demograficznych i środowiskowych.

Uwaga metodologiczna: oryginalne dane Fagny i in. [1] pochodzą z macierzy mikromacierzowej (Illumina 450K, wartości β). W niniejszej pracy, aby uzyskać rozdzielczość pojedynczego CpG w skali całego genomu oraz dane w postaci zliczeń odczytów zgodne z testami różnicowymi opartymi na modelach zliczeniowych (sekcja DMS), wybrano technikę sekwencyjną — **enzymatyczne sekwencjonowanie metylacji (EM-seq)**. Macierz 450K pokrywa jedynie ułamek pozycji CpG genomu, podczas gdy EM-seq zapewnia profilowanie całogenomowe [8].

1.2.2.2 Procedura

Proces obejmuje pozyskanie materiału i ekstrakcję DNA, enzymatyczną konwersję i przygotowanie bibliotek (EM-seq), wstępne przetwarzanie i mapowanie odczytów, ekstrakcję sygnału metylacji i budowę macierzy zliczeń CpG, a następnie filtrowanie oraz eksploracyjną kontrolę jakości.

1.2.2.2.1 Pozyskanie materiału i ekstrakcja DNA

Materiał referencyjny stanowi współczesna tkanka kostna (preferencyjnie kość zbita lub część skalista kości skroniowej — *petrous bone*), pozyskiwana ze współczesnego materiału szkieletowego/sekcyjnego. Wybór tkanki kostnej, a nie krwi obwodowej zastosowanej w oryginalnej analizie referencyjnej [1], jest podyktowany silną tkankową specyficznością metylacji DNA: mapy współczesne muszą pochodzić z tej samej tkanki co kopalne aDNA (materiał szkieletowy), aby porównanie HG vs. AGR nie było obciążone różnicą typu tkanki. Ze względu na heterogeniczność komórkową tkanki kostnej (m.in. osteoblasty, osteocyty, osteoklasty oraz domieszka komórek szpiku) równolegle szacuje się skład komórkowy próbki, co umożliwia późniejszą korektę tej heterogeniczności. Wyizolowane DNA genomowe poddaje się kontroli ilości i integralności, a wymaganą masę wejściową dobiera się zgodnie z protokołem przygotowania bibliotek EM-seq, który pozwala na pracę z niewielkimi ilościami materiału [8].

1.2.2.2.2 Konwersja enzymatyczna i przygotowanie bibliotek (EM-seq)

Do rozróżnienia cytozyn metylowanych i niemetylowanych stosujemy enzymatyczne sekwencjonowanie metylacji (EM-seq), w którym konwersja zachodzi w dwóch krokach enzymatycznych zamiast chemicznej konwersji dwusiarczynowej [8]. W pierwszym kroku enzymy z rodziny TET (TET2) wraz z utleniaczem przekształcają 5-metylocytozynę (5mC) i 5-hydroksymetylocytozynę do form chroniących te zasady przed deaminacją. W drugim kroku deaminaza APOBEC deaminuje wyłącznie niemodyfikowane cytozyny do uracyli. W rezultacie, po amplifikacji i sekwencjonowaniu, pozycje niemetylowane odczytywane są jako tymina (T), a pozycje metylowane pozostają cytozyną (C), generując sygnał metylacji analogiczny do uzyskiwanego metodą dwusiarczynową, lecz przy łagodniejszej obróbce DNA i wyższej wydajności mapowania oraz pokrycia [8].

1.2.2.2.3 Wstępne przetwarzanie odczytów i mapowanie do genomu referencyjnego

Surowe odczyty poddaje się kontroli jakości oraz przycinaniu adapterów i zasad o niskiej jakości (FastQC, fastp), a następnie mapuje do ludzkiego genomu referencyjnego (GRCh38) z wykorzystaniem programu mapującego uwzględniającego konwersję (Bismark lub BWA-Meth), zorganizowanego w ramach zautomatyzowanego potoku nf-core/methylseq [9], [10], [11]. Wybór genomu GRCh38 zapewnia spójność współrzędnych z mapami kopalnymi oraz z danymi referencyjnymi. Powstałe pliki BAM sortuje się, indeksuje i oczyszcza z duplikatów PCR przy użyciu samtools, a wynik można skontrolować wizualnie w przeglądarce IGV; zbiorcze raporty jakości z poszczególnych etapów agreguje się narzędziem MultiQC [12].

1.2.2.2.4 Ekstrakcja sygnału metylacji i budowa macierzy zliczeń CpG

Po zmapowaniu sygnał metylacji ekstrahuje się na poziomie pojedynczych pozycji CpG (`MethylDackel` lub moduł ekstrakcji metylacji `Bismark`), uzyskując dla każdej pozycji liczbę odczytów metylowanych i niemetylowanych [9]. Komplementarne pomiary z obu nici DNA dla tej samej pozycji CpG łączy się (*strand merging*), a pozycje o pokryciu poniżej przyjętego progu odrzuca się, aby ograniczyć szum wynikający z niskiej liczby odczytów. Wynikiem tego kroku jest macierz zliczeń CpG (poziom metylacji wyrażony jako udział odczytów metylowanych wraz z pokryciem), stanowiąca właściwą mapę metylacji wykorzystywaną w dalszej analizie.

1.2.2.2.5 Filtrowanie pozycji, maskowanie SNP i korekta zmiennych zakłócających

Aby ograniczyć artefakty, z macierzy usuwa się pozycje pokrywające się ze znanymi polimorfizmami pojedynczego nukleotydu (maskowanie SNP) oraz pozycje w regionach problematycznych (listy wykluczeń, *blacklist*), ponieważ wariant genetyczny w miejscu CpG może imitować zmianę stanu metylacji. W celu kontroli wpływu pochodzenia genetycznego na metylację osobniki genotypuje się niezależnie [1].

Następnie koryguje się dwie kluczowe zmienne zakłócające: heterogeniczność składu komórkowego (na podstawie oszacowanych proporcji typów komórek tkanki kostnej) oraz wiek osobnika, zgodnie z podejściem zastosowanym dla populacji referencyjnych [1].

1.2.2.2.6 Eksploracyjna kontrola jakości map populacyjnych

Przed przekazaniem map do detekcji DMS przeprowadza się eksploracyjną kontrolę jakości: ocenę rozkładu pokrycia, globalnego rozkładu poziomów metylacji, analizę głównych składowych (PCA/MDS), grupowanie próbek oraz ocenę efektów wsadowych (*batch effects*). Dodatkowo, na podstawie kontroli konwersji (λ /pUC19) weryfikuje się wydajność konwersji enzymatycznej dla każdej biblioteki [8]. Próbkę odstającą lub o niewystarczającej jakości (niskie pokrycie, nieprawidłowa wydajność konwersji) są odrzucane z dalszej analizy.

1.2.3 Mapy metylacyjne dla populacji kopalnych

1.2.3.1 Wstęp

Celem tej części metodologii jest odtworzenie populacyjnych map metylacji dla kopalnych kohort walidacyjnych o jednoznacznym trybie życia, czyli dla grup *zbieracko-łowieckich* (HG) oraz *rolniczych* (AGR), oraz dla populacji nie jednoznacznych, między innymi Çatalhöyük.

Mapy te dostarczają wartości m^j wykorzystywanych później w teście klasyfikacyjnym. Ponieważ pojedyncze próbki, uzyskane metodą “Twist Ancient DNA” mają zbyt niskie pokrycie do rekonstrukcji indywidualnej [13], [14], mapy budujemy na poziomie populacji, łącząc odczyty wielu osobników z tej samej kohorty. Mapy posłużą potem do walidacji metody.

Choć Çatalhöyük jest zwykle klasyfikowane jako osiedle rolnicze (AGR), jest przejściowe / niejednoznaczne pod względem strategii bytowania.

1.2.3.2 Procedura

Proces przetwarzania danych obejmuje ekstrakcję sygnału deaminacji, filtrowanie artefaktów, nieliniowe dopasowanie histogramów oraz wygładzanie sygnału metodą okien przesuwnych zgodnie z podejściem zaimplementowanym w pakietach referencyjnych [4], [6]. Poniżej opisano kolejne kroki potoku — od doboru kohort, przez przygotowanie danych sekwencyjnych i właściwą rekonstrukcję metylacji, po detekcję regionów różnicowo zmetylowanych — zachowując analogiczną strukturę względem części dotyczącej populacji współczesnych.

1.2.3.2.1 Przygotowanie bibliotek aDNA: Ekstrakcja i konwersja

Procedura laboratoryjna przygotowania materiału kostnego oraz izolacji kopalnego DNA (aDNA) opiera się na protokole, który został opisany w [15], co pozwala na zminimalizowanie ryzyka kontaminacji współczesnym materiałem biologicznym. Proces ten obejmuje następujące kroki:

1. **Dekontaminacja powierzchniowa i pobranie próby:** W kroku tym zewnętrzna warstwa tkanki kostnej (części skalistej kości skroniowej lub zębów) zostaje mechanicznie oczyszczona za pomocą wiertła stomatologicznego lub poddana krótkiemu naświetlaniu promieniowaniem UV-C. Działanie to ma na celu usunięcie egzogenego DNA. Następnie z warstwy o najwyższej gęstości osteocytów wywierca się od 50 do 100 mg drobnego proszku kostnego, co pozwala maksymalnie zwiększyć stężenie endogenego aDNA.
2. **Liza i trawienie enzymatyczne:** W kroku tym uzyskany proszek kostny zostaje zawieszony w buforze ekstrakcyjnym zawierającym kwas etylenodiaminotetraoctowy (EDTA) oraz Proteinazę K. Zastosowanie EDTA pozwala na rozpuszczenie hydroksyapatytowej matrycy kości i uwolnienie uwięzionych w niej cząsteczek kwasów nukleinowych, natomiast Proteinaza K jako enzym proteolityczny trawi białka komórkowe, w tym kolagen i nukleazy. Inkubacja prowadzona w temperaturze 56°C zapewnia całkowite uwolnienie uwięzionego DNA.
3. **Wiązanie i oczyszczanie na kolumnach krzemionkowych:** W kroku tym zawiesina zostaje odwirowana, a supernatant wymieszany z buforem wiążącym o wysokim stężeniu soli chaotropowych (chlorowodoru guanidyny). Sól chaotropowa niszczy otoczkę hydratacyjną DNA, co umożliwia jego selektywne i silne wiązanie z membraną krzemionkową w mikrokolumnach. Po serii etapów przemycania buforami na bazie etanolu w celu usunięcia inhibitorów polimerazy, czyste aDNA zostaje wyemitowane przy użyciu niskosolnego buforu TE.
4. **Przygotowanie bibliotek sekwencyjnych (Konwersja):** W kroku tym wyizolowane aDNA zostaje poddane procedurze ligacji specyficznych adapterów sekwencyjnych w formacie single-stranded (ssDNA) lub double-stranded (dsDNA) zgodnie z metodologią optymalizacji dla silnie zdegradowanych cząsteczek [15]. Ze względu na silną degradację post-mortem, cząsteczki te charakteryzują się obecnością pęknięć jednoniciowych oraz deaminacją cytozyny do uracylu na końcach fragmentów [2]. Proces konwersji przygotowuje te uszkodzone cząsteczki do wydajnej amplifikacji PCR, nadając im unikalne indeksy identyfikujące próbkę.

1.2.3.2.2 Wzbogacona hybrydyzacja in-solution (Twist Ancient DNA)

W kopalnych próbach kostnych endogenne aDNA stanowi zazwyczaj jedynie niewielki ułamek całkowitego wyekstrahowanego DNA (wyekstrahowane DNA $\leq 10\%$) [13], [16], w którym dominują cząsteczki pochodzenia środowiskowego, takie jak DNA bakterii i grzybów glebowych [16], [17]. Aby rozwiązać problem niskiej zawartości matrycy, usunąć zanieczyszczenia mikrobiologiczne i uzyskać czyste dane o wysokiej specyficzności, w procesie tym zastosujemy technologię wzbogacania ukierunkowanego (*target enrichment*) w układzie *in-solution capture* przy użyciu dedykowanej platformy Twist Ancient DNA [13]. Metoda ta pozwala na wybiórcze wyłapanie ludzkich cząsteczek, co w przypadku bardzo słabo zachowanych próbek zwiększa frakcję DNA endogennego wielokrotnie w stosunku do sekwencjonowania bezpośredniego (shotgun), drastycznie zmniejszając tło sekwencyjne generowane przez organizmy egzogenne [13].

Fizykochemia tego procesu oraz mechanizm selekcji opierają się na następujących założeniach: - **Fizyczna struktura sond i komplementarność:** W procesie tym zastosujemy biotynowane, jednoniciowe sondy RNA o długości 80 par zasad (bp), których sekwencja jest ściśle komplementarna do docelowych, ludzkich regionów genomowych [14]. Po denaturacji cieplnej biblioteki DNA, sondy hybrydują z komplementarnymi cząsteczkami aDNA. Kompleksy sonda-aDNA są następnie fizycznie wyłapywane z roztworu za pomocą kulek magnetycznych opłaszczonych streptawidyną, natomiast nieskomplementowane DNA środowiskowe zostaje całkowicie wymyte. Należy podkreślić, że technologia ta eliminuje kontaminację mikrobiologiczną, lecz nie usuwa zanieczyszczeń współczesnym DNA ludzkim ze względu na identyczność sekwencji; ich detekcja zachodzi na drodze bioinformatycznej. - **Wpływ degradacji aDNA na długość odczytów:** Naturalna, pośmiertna fragmentacja, wynikająca z chemicznej hydrolizy wiązań fosfodiesterowych oraz aktywności nukleaz, powoduje, że cząsteczki aDNA są wysoce zdegradowane i ultrakrótkie, a ich średnia długość w bibliotece często spada poniżej 80 bp [15]. Ponieważ sondy Twist mają długość 80 bp, w przeciwieństwie do 52 bp stosowanych w klasycznym panelu 1240K [13]. Zapewniają one wyższą stabilność termodynamiczną i wydajność hybrydyzacji z ultrakrótkimi fragmentami matrycy. Pozwala to na efektywne wiązanie cząsteczek, których fizyczna długość w roztworze uniemożliwia stabilne mapowanie przy użyciu krótszych sond. W rezultacie, po zmapowaniu odczytów do genomu referencyjnego, uzyskuje się fragmenty pokrywające pozycję docelową (SNP) wraz z jej bezpośrednim otoczeniem, pokrywające region o długości maksymalnie około 80-100 bp wokół pozycji docelowej [13]. - **Charakterystyka funkcjonalna celów genomowych:** Sondy panelu Twist zostały zaprojektowane tak, aby celować w kluczowe pod względem ewolucyjnym i funkcjonalnym obszary ludzkiego genomu [13]. Struktura paneli obejmuje następujące komponenty: 1. *Komponent populacyjny (Rdzeń 1240K):* Pozycje polimorficzne (SNP) na chromosomach autosomalnych oraz chromosomie X, które opisali Haak i in. (2015) oraz Olalde i in. (2018) [18], [19], [20], kluczowe dla rekonstrukcji historycznych migracji, demografii oraz pokrewieństwa [21], [22]. 1. *Regiony kodujące i regulatorowe (Zawartość fenotypowa):* Lokusy powiązane bezpośrednio z ekspresją cech fizycznych, wyselekcjonowane z baz takich jak ClinVar, GWAS czy PolyFun [20]. Pozwala to na bezpośrednią analizę funkcjonalnych zmian adaptacyjnych w sekwencjach kodujących białka oraz w regionach promotorowych i enhancerowych. 2. *Regiony konserwatywne i epigenetyczne:* Obszary HAR (*Human Accelerated Regions*) oraz pozycje metylacyjne służące do analizy epigenetycznego starzenia się tkanek i rekonstrukcji starożytnych metylomów (Zegary Horvatha i Narasimhana) [23], [24], co koresponduje z modelami epigenetycznymi opracowanymi dla populacji kopalnych i współczesnych [1], [3], [4].

1.2.3.2.3 Biochemiczne generowanie asymetrii sygnału (Traktowanie enzymem USER)

W celu umożliwienia matematycznej rekonstrukcji przedśmiertnych wzorców metylacji, procedurę przygotowania bibliotek po etapie wzbogacenia Twist uzupełnia się o kontrolowane traktowanie kwasów nukleinowych enzymem USER (*Uracil-Specific Excision Reagent*) [6]. Naturalna, pośmiertna deaminacja uszkadza kopalne DNA w dwojaki sposób: niemetylowane cytozyny przekształcają się w uracyle, podczas gdy metylowane 5-metylocytozyny (5mC) ulegają konwersji do tyminu [2]. Dodatek enzymu USER przed etapem amplifikacji PCR skutkuje selektywnym niszczeniem i wycinaniem cząsteczek uracylu (pochodzących z loci niemetylowanych), uniemożliwiając ich dalszą replikację i sekwencjonowanie [2], [6]. Cząsteczki tyminy (pochodzące z pozycji metylowanych) pozostają nienaruszone przez enzym, dzięki czemu pomyślnie przechodzą proces amplifikacji, generując w odczytach sekwencyjnych asymetrię przejść C → T ściśle skorelowaną z pierwotnym stanem epigenetycznym [6].

1.2.3.2.4 Wstępne przetwarzanie odczytów i mapowanie do genomu referencyjnego

Surowe odczyty kopalnych bibliotek poddaje się kontroli jakości i przycinaniu adapterów (**FastQC**, **fastp**), a następnie mapuje do ludzkiego genomu referencyjnego (GRCh38). Należy uwzględnić, że odczyty aDNA są **bardzo krótkie** (zwykle $\approx 30\text{--}70$ pz wskutek pośmiertnej fragmentacji), co utrudnia jednoznaczne mapowanie, ponieważ krótkie odczyty częściej dopasowują się wieloznacznie, szczególnie w regionach powtarzalnych. Z tego powodu w analizie aDNA standardem jest program mapujący **bwa aln/samse** (BWA-backtrack) [25], który lepiej radzi sobie z krótkimi i uszkodzonymi odczytami niż **bwa mem** (zaprojektowany dla odczytów $> \approx 70$ pz) [26]. Dodatkowo odrzuca się odczyty krótsze niż $\sim 30\text{--}35$ pz, stosuje filtr jakości mapowania (MAPQ) oraz rozluźnia parametry dopasowania lub przeskalowuje oceny jakości poszczególnych zasad (np. programem **mapDamage**), aby uwzględnić niedopasowania wynikające z deaminacji na końcach fragmentów [27]. Zastosowanie sond panelu Twist łagodzi ten problem, ponieważ sondy celują w unikatowe, dobrze zdefiniowane loci wokół SNP (~ 100 pz), do których nawet krótkie odczyty mapują się względnie jednoznacznie. Powstałe pliki BAM sortuje się, indeksuje oraz oczyszcza z duplikatów PCR przy użyciu **samtools**, a wynik można skontrolować wizualnie w przeglądarce **IGV** [5], [6]. Wyniki te są zapisywane w postaci plików **bam**, **bai**.

1.2.3.2.5 Globalna ocena jakości i autentykacja próbek kopalnych

Po przeprowadzeniu sekwencjonowania wysokoprzepustowego (NGS) i wstępnego zmapowania, surowe dane w formacie BAM zostają poddane rygorystycznej procedurze filtracji całogenomowej w celu odrzucenia osobników o niskiej jakości lub wykazujących krytyczny poziom współczesnych zanieczyszczeń:

1. **Weryfikacja frakcji endogennej:** W kroku tym ocenia się ogólny stopień zachowania próby poprzez wyznaczenie stosunku odczytów mapujących się do ludzkiego genomu referencyjnego (GRCh38) do całkowitej liczby uzyskanych sekwencji [5]. Próbkę charakteryzującą się zbyt niską frakcją odczytów endogennych, wynikającą z przewagi tła środowiskowego (DNA mikroorganizmów glebowych), zostają bezwzględnie odrzucone z dalszych etapów obliczeniowych [16], [17].
2. **Kwantyfikacja kontaminacji współczesnym DNA ludzkim:** W kroku tym szacuje się poziom zanieczyszczenia współczesnym ludzkim DNA [3], [4]. W przypadku osobników płci męskiej analizuje się poziom heterozygotyczności na chromosomie X, natomiast dla całej kohorty bada się polimorfizm

DNA mitochondrialnego. Dane te są procesowane za pomocą pakietów przeznaczonych do weryfikacji czystości starożytnych genomów [6]. Próbkę, w której oszacowany poziom kontaminacji współczesnym ludzkim DNA przekracza próg tolerancji ($> 1 - 3\%$), zostają usunięte z ostatecznej kohorty.

1.2.4 Symulacja DMS

1.2.4.1 Wstęp

Dla porównania skuteczności, zostanie dodatkowo przeprowadzona analiza wykorzystująca sztucznie zanieczyszczone i pofragmentowane sekwencje współczesne, symulujące aDNA. Dzięki temu sprawdzimy, czy wybrane przez nas parametry do analizy dają wiarygodne wyniki. Pomoże nam to również ustalić, z jakiego zakresu czasowego mogą pochodzić analizowane w ten sposób szczątki.

1.2.4.2 Procedura

1.2.4.2.1 Przygotowanie danych

Całość procesu symulacji zanieczyszczenia danych opiera się na wykorzystaniu opcji dostępnych w narzędziu gargammel [28], które zostało zaprojektowane właśnie do symulowania danych antycznych.

1. Sekwencje ludzkie będą pobrane z bazy NIH [29].
2. Zostaną one podzielone na fragmenty wielkości 30-80 par zasad.
3. Dodamy sekwencje egzogenne pochodzenia bakteryjnego, odpowiadające mikroorganizmom charakterystycznym dla tych znajdujących w szczątkach badanego rejonu geograficznego.
4. Dodane również zostaną charakterystyczne uszkodzenia zachodzące w procesie degradacji DNA post mortem.

1.2.4.2.2 Analiza bioinformatyczna

Przygotowane dane zostaną poddane ocenie jakości przy wykorzystaniu programu FastQC. Ewentualne filtrowanie i przycinanie sekwencji o zbyt niskiej jakości zostanie przeprowadzone wykorzystując program fastp. Odczyty zostaną zmapowane do genomu referencyjnego człowieka (GRCh38) programem BWA. Obce sekwencje usunięte zostaną narzędziem BlobTools.

1.2.5 Analiza DMS dla populacji współczesnych

1.2.5.1 Wstęp

Dotychczasowa charakterystyka różnic epigenetycznych między populacjami łowiecko-zbierackimi (HG) a rolniczymi (AGR) opiera się przede wszystkim na analizie jednej pary populacji z jednego regionu — afrykańskich łowców-zbieraczy lasu deszczowego oraz sąsiadujących z nimi rolników [1]. Oparcie referencyjnych sygnatur metylacji na pojedynczej parze populacji wiąże się z dwoma istotnymi ograniczeniami.

Po pierwsze, mała liczba niezależnych populacji ogranicza moc statystyczną i wiarygodność identyfikowanych miejsc różnicowo metylowanych (DMS). Po drugie, różnice obserwowane między jedną parą HG/AGR mogą być zaburzone przez pochodzenie genetyczne, lokalną historię demograficzną oraz specyfikę środowiska, w tym klimat lasu równikowego [1]. W takim układzie trudno rozstrzygnąć, czy wykryty sygnał odzwierciedla rzeczywisty efekt trybu życia, czy raczej lokalną różnicę typu „populacja A vs. populacja B”.

Rozwiązaniem tego problemu jest włączenie wielu niezależnych par HG/AGR pochodzących z różnych kontynentów i stref klimatycznych. Sygnatury epigenetyczne powtarzalne w wielu takich porównaniach z dużo większym prawdopodobieństwem odzwierciedlają uniwersalny komponent związany z trybem życia, a nie lokalne uwarunkowania genetyczne, demograficzne lub środowiskowe.

1.2.5.2 Procedura

1.2.5.2.1 Identyfikacja miejsc różnicowo zmetylowanych (DMS)

Określenie miejsc o zróżnicowanym stopniu metylacji między populacjami opiera się na modelowaniu liczby odczytów metylowanych i niemetylowanych w każdej pozycji CpG, uzyskanych z populacyjnych map EM-seq. W przeciwieństwie do oryginalnej analizy mikromacierzowej, w której stosowano model liniowy ciągłych wartości M z empirycznym wygładzeniem Bayesa (pakiet `limma`) [1], dane sekwencyjne modelujemy testem opartym na rozkładzie beta-dwumianowym, uwzględniającym zmienność biologiczną oraz pokrycie (pakiet `DSS`) [30]. Dla każdej pozycji CpG porównujemy średni poziom metylacji między dwiema populacjami (HG vs. AGR) testem Walda, gdzie zmienną objaśnianą jest udział odczytów metylowanych w całkowitym pokryciu pozycji [30]. Wpływ zmiennych zakłócających to jest: płci, wieku oraz proporcji typów komórek, które w analizie referencyjnej wprowadzano jako współzmiennne modelu liniowego [1], ograniczamy na etapie poprzedzającym test poprzez dopasowanie i stratyfikację próbek. Uzyskane wartości P koryguje się metodą Benjamini-Hochberga, a pozycje o skorygowanej wartości $P < 0,01$ uznaje się za różnicowo metylowane [30].

Aby zdefiniować amplitudę zmian i wyodrębnić DMS, stosujemy rygorystyczne kryteria obejmujące skorygowaną wartość $P < 0,01$ oraz różnicę w średnim poziomie metylacji między dwiema populacjami ($\Delta\beta$) wynoszącą ponad 10% [1]. Poziom metylacji w tej analizie określa się jako stosunek liczby odczytów metylowanych do całkowitej liczby odczytów (pokrycia) w danej pozycji CpG, reprezentujący wartość beta (β) [30]. W procesie tym wyodrębniamy nakładające się fragmenty między różnymi zestawami DMS i obliczamy wartości P mierzące prawdopodobieństwo uzyskania tych nakładających się fragmentów przez przypadek, stosując ponowne próbkowanie (resampling) [1]. Ponieważ poziomy metylacji DNA w

docelowych miejscach są silnie skorelowane w obrębie regionów o określonej wielkości wynoszącej około 2000 bp, dla każdej listy DMS losowo pobieramy ponownie taką samą liczbę spośród wszystkich miejsc, biorąc pod uwagę faktyczną odległość chromosomalną między poszczególnymi DMS [1].

1.2.5.2.2 Analiza funkcjonalna i ontologia genów

W tym kroku wyodrębniamy geny o zróżnicowanym stopniu metylacji, definiowane jako geny zawierające co najmniej jeden DMS [1]. Analizę nadreprezentacji kategorii ontologii genów (GO) wśród tych genów przeprowadzamy pakietem `goseq` [31], zgodnie ze strategią analizy referencyjnej [1]. W odróżnieniu od oryginalnej analizy mikromacierzowej (ważenie liczbą sond) jako miarę obciążenia detekcji stosujemy liczbę pozycji CpG o wystarczającym pokryciu przypadającą na gen, co koryguje większą szansę wykrycia DMS w genach o wyższej gęstości CpG [31].

Funkcja ważenia prawdopodobieństwa ogranicza to obciążenie w obrębie testowanego tła, które stanowią wyłącznie geny posiadające pozycje CpG o wystarczającym pokryciu. Daną kategorię GO uznaje się za istotnie wzbogaconą w genach zawierających DMS, jeśli obliczona dla niej wartość P, skorygowana o współczynnik fałszywych odkryć (FDR) po wszystkich kategoriach, wynosi maksymalnie 0,05 [1].

1.2.6 Analiza DMS dla populacji kopalnych

1.2.6.1 Wstęp

Rekonstrukcja stanów metylacji dla populacji antycznych opiera się na specyficznych właściwościach degradacji post-mortem, umożliwiając binarne określenie statusu epigenetycznego zachowanych loci [2], [3]. Ze względu na unikalną architekturę danych uzyskiwanych z paneli wzbogacanych, potok analityczny nie dąży do wyznaczenia ciągłych wartości ilościowych, lecz ma na celu precyzyjne określenie, czy dany region genomowy był metylowany [4], [6]. Uzyskane w ten sposób binarne profile epigenetyczne starożytnych próbek podlegają bezpośredniemu mapowaniu i porównaniu z referencyjnymi obszarami DMS zidentyfikowanymi u populacji współczesnych, co pozwala na uchwycenie specyficznych zmian ewolucyjnych związanych z trybem życia.

W celu porównania skuteczności i czułości potoku interpretacji epigenetycznej, cała procedura analityczna zostaje równolegle przeprowadzona zarówno dla autentycznych próbek kopalnych, jak i dla syntetycznych zbiorów danych. Dane symulowane stanowią sztucznie zanieczyszczone i pofragmentowane sekwencje współczesne, które odzwierciedlają profil uszkodzeń post-mortem charakterystyczny dla aDNA. Przetwarzanie obu tych kohort (prawdziwej i symulowanej) przebiega w sposób identyczny na poziomie plików BAM oczyszczonych z duplikatów sekwencyjnych.

1.2.6.2 Procedura

1.2.6.2.1 Ekstrakcja sygnału metylacji (wskaźnik $C \rightarrow T$)

Wejściowy sygnał metylacji odzyskuje się bezpośrednio ze specyficznego wzorca deaminacji, będącego dominującym procesem chemicznej degradacji starożytnego DNA [2]. Podczas post-mortem uszkodzeń niemetylowana cytozyna deaminuje do uracylu, natomiast metylowana 5-metylocytozyna deaminuje do tyminy [2]. Ponieważ na etapie przygotowania bibliotek stosujemy częściowe, kontrolowane traktowanie enzymem USER, fragmenty zawierające uracyl (pochodzący z pozycji niemetylowanych) ulegają enzymatycznemu rozczepieniu, wykluczającemu je z sekwencjonowania [6]. W rezultacie, odczytane w sekwencjonowaniu tyminy w pozycjach CpG reprezentują wyłącznie pozycje pierwotnie metylowane przed śmiercią osobnika, które jako tyminy uniknęły działania USER [6]. Dla każdej pozycji i definiuje się matematyczny wskaźnik deaminacji:

$$C \rightarrow T(i) = \frac{t_i}{t_i + c_i},$$

gdzie t_i oraz c_i oznaczają liczby odczytów odpowiednio z tyminą i cytozyną w danej pozycji CpG; wyższy wskaźnik bezpośrednio odpowiada wyższemu poziomowi metylacji przedśmiertnej [3], [4]. Dla bibliotek zachowujących strukturę dwuniciową zlicza się dodatkowo komplementarne zdarzenia $G \rightarrow A$ na nici przeciwne [6].

1.2.6.2.2 Filtrowanie pozycji CpG

Z dalszej analizy usuwa się pozycje niewiarygodne dla matematycznej rekonstrukcji mapy epigenetycznej [4], [6]: - **Pozycje o anomalnie wysokim pokryciu (Extreme Coverage)** — loci wykazujące nienaturalnie wysoką głębokość pokrycia odczytami, identyfikowane na podstawie histogramu pokrycia liczonego osobno dla każdego chromosomu. W procesie tym próg odcięcia wyznaczany jest automatycznie metodą rozstępu międzykwartylowego z parametrem rozpiętości (np. w pakiecie RoAM), co pozwala wyeliminować fałszywy sygnał pochodzący ze złego mapowania w regionach duplikacji segmentalnych i powtórzeń genomu [6]. - **Domniemane mutacje $C \rightarrow T$** — pozycje, w których wskaźnik $C \rightarrow T$ przekracza sztywny próg (np. $> 0,25$), co może indykować mutację genetyczną, a nie modyfikację epigenetyczną [6]. W pakiecie RoAM dodatkowo modeluje się rozkład tymin jako mieszaninę trzech rozkładów dwumianowych (odzwierciedlających odpowiednio mutacje homozygotyczne, heterozygotyczne oraz właściwą deaminację pośmiertną), a precyzyjny próg odrzucenia wyznacza się statystycznie metodą maksymalizacji oczekiwania (algorytm EM) [6]. - **####** Estymacja tempa deaminacji Globalne lub lokalne tempo deaminacji π estymuje się na podstawie pozycji CpG, których poziom metylacji w referencyjnej mapie współczesnej tkanki kostnej jest bliski jedności: $\hat{\pi} = \sum t_i / \sum n_i$ po tych pozycjach [6]. Przy braku mapy referencyjnej, algorytm wykorzystuje założoną globalną średnią metylację wyliczoną bezpośrednio dla badanej próbki kopalnej [6].

1.2.6.2.3 Pulowanie osobników i rekonstrukcja mapy populacyjnej

Ponieważ pojedyncze próbki wzbogacane panelem docelowym mają często zbyt niskie indywidualne pokrycie dla samodzielnej rekonstrukcji, binarną mapę stanów buduje się na poziomie całej populacji poprzez

pulowanie (łączenie) odczytów wielu osobników [4]: - **Łączenie naiwne** — polega na prostym sumowaniu liczników C i T w każdej pozycji CpG bezpośrednio ze wszystkich osobników wchodzących w skład danej kohorty [4]. W praktyce podejście to wykazuje zbliżoną lub wyższą stabilność niż wariant zaawansowany uwzględniający indywidualne wahania tempa deaminacji (gdzie estymacja największej wiarygodności jest rozwiązywana numerycznie metodą Newtona–Raphsona) [4]. - **Mapowanie wskaźnika $C \rightarrow T$ na metylację** - realizowane metodą dopasowywania histogramów (*histogram matching*), polegającą na nieliniowym dopasowaniu uzyskanych wskaźników $C \rightarrow T$ do referencyjnego histogramu metylacji ludzkiej tkanki kostnej [6]. Alternatywnie, pakiet RoAM oferuje przeprowadzenie transformacji liniowej obciętej oraz przekształcenia logistycznego [6]. - **Wygładzanie w przesuwym oknie** - proces rekonstrukcji prowadzi się w zdefiniowanym oknie W obejmującym kolejne pozycje CpG (okno o nieparzystej liczbie loci, gdzie ostateczna wartość zostaje przypisana pozycji środkowej), ze względu na silną korelację poziomów metylacji sąsiadujących CpG na dystansie do ≈ 2 kbp [6]. Rozmiar okna dobiera się automatycznie za pomocą metod probabilistycznych lub analizy błędu względnego, bezpośrednio dostosowując go do efektywnego pokrycia badanej kohorty [6].

1.2.6.2.4 Kontrola efektywnego pokrycia

Wiarygodna i stabilna rekonstrukcja stanów metylacji na poziomie populacyjnym wymaga zachowania **efektywnego pokrycia na poziomie ≥ 12** [4]. Efektywne pokrycie kohorty można oszacować matematycznie z góry za pomocą modelu regresji liniowej, przyjmując jako zmienne liczbę pulowanych osobników oraz ich średnią liczbę unikalnych trafień w autosomalne loci SNP ($R^2 = 0,99$ w modelach referencyjnych) [4].

1.2.6.2.5 Mapowanie i porównanie profili metylacji z referencją współczesną

Uzyskane populacyjne mapy stanów metylacji dla kohort kopalnych (zarówno dla danych autentycznych, jak i zbiorów symulowanych) zostają poddane procedurze nakładania przestrzennego z ilościowymi macierzami referencyjnymi zidentyfikowanymi u ludności współczesnej [4]. Algorytm mapuje binarne stany metylacji kopalnych pozycji CpG bezpośrednio na współrzędne genomowe uniwersalnych miejsc różnicowo metylowanych (DMS), wyznaczanych testem beta-dwumianowym (pakiet DSS) [30]. Pozwala to na precyzyjne określenie statusu epigenetycznego starożytnych kohort w oknach funkcjonalnych i identyfikację, które cechy metylacji specyficzne dla danego trybu życia były już utrwalone w badanych okresach historycznych [4].

1.2.6.2.6 Walidacja biologiczna i ewolucyjna map

Poprawność merytoryczną zrekonstruowanych map starożytnych weryfikuje się poprzez kontrolę obecności uniwersalnych cech biologicznych: głębokiej hipometylacji wysp CpG oraz promotorów genów metabolizmu podstawowego (*housekeeping genes*), podwyższonej metylacji elementów powtarzalnych, a także najwyższej korelacji ze współczesnymi referencyjnymi metylomami komórek tkanki kostnej [4]. Zwalidowane pod kątem ewolucyjnym i strukturalnym profile metylacji służą jako niezależny układ odniesienia, umożliwiając ocenę stopnia ciągłości epigenetycznej oraz kierunku zmian funkcjonalnych w genomie ludzkim na przestrzeni dziejów, bez ryzyka zaburzenia wyników przez pośmiertną degradację próby [4], [6].

1.2.7 Metoda statystyczna do porównywania populacji.

1.2.7.1 Oznaczenia

Niech K oznacza liczbę zidentyfikowanych DMS.

Dla każdego locus $j \in \{1, \dots, K\}$ wyznaczamy referencyjne częstości metylacji na podstawie wyników z analizy DMS dla populacji łowców ($p_j^{\text{HG}} \in [0, 1]$) oraz rolników ($p_j^{\text{AGR}} \in [0, 1]$).

Dla badanej nieznanej populacji kopalnej X w wyniku map metylacyjnych otrzymujemy poziom metylacji dla każdego locus j , oznaczany jako $\hat{m}_j \in [0, 1]$.

1.2.7.2 Test klasyfikacyjny

Test klasyfikacyjny ma za zadanie sprawdzić, czy dana populacja jest istotnie podobna do populacji agrarnej (AGR) lub tradycyjnej grupy łowiecko-zbierackiej (HG).

Statystykę testową D_{EPM} (Weighted Epigenetic Profile Matching Statistic) definiujemy jako:

$$D_{\text{EPM}}(X) = \sum_{j=1}^K w_j \left[(\hat{m}_j - p_j^{\text{AGR}})^2 - (\hat{m}_j - p_j^{\text{HG}})^2 \right]$$

Gdzie: - $w_j = |p_j^{\text{HG}} - p_j^{\text{AGR}}|$ mówi o tym, jak dany locus jest informatywny. - $D(X) < 0$ jest klasyfikowana jako populacja łowców. - $D(X) > 0$ jest klasyfikowana jako populacja rolników.

Żeby sprawdzić istotność tej zmiany, definiujemy następujące hipotezy: - H_0 : profil metylacji nie wykazuje specyficznego ukierunkowania. - H_1 : profil metylacji wskazuje istotne podobieństwo do jednej z grup.

Oraz stosujemy testy permutacyjne względem wartości $\hat{m}_j$.

1.2.7.3 Testy profilowe

Testy profilowe mają za zadanie identyfikację, czy istotnie występuje metylacja regionów (zbioru DMS) o określonym znaczeniu biologicznym. Regiony te będziemy nazywać grupami funkcjonalnymi, jest to podzbiór zidentyfikowanych loci. Niech $\mathcal{G}$ oznacza zbiór grup funkcjonalnych.

Dla każdej grupy $G \in \mathcal{G}$ definiujemy statystykę testową Λ_G jako:

$$\Lambda_G(X) = \frac{\sum_{j \in G} (\hat{m}_j - p_j^{\text{AGR}})^2 - \sum_{j \in G} (\hat{m}_j - p_j^{\text{HG}})^2}{\sum_{j \in G} (p_j^{\text{HG}} - p_j^{\text{AGR}})^2} \in [-1, 1]$$

Gdzie skala opisuje bliskość względem populacji łowców i populacji rolników.

Żeby sprawdzić istotność każdej z tych zmian, definiujemy następujące hipotezy: - H_0^G : profil metylacji grupy funkcjonalnej G nie wykazuje specyficznego ukierunkowania. - H_1^G : profil metylacji grupy funkcjonalnej G wskazuje istotne podobieństwo do jednej z grup.

Oraz stosujemy testy permutacyjne względem zbioru G , biorąc losowe DMS.

1.3 Oczekiwane wyniki

1.3.1 Cechy charakterystyczne

Możemy się spodziewać wykrycia cech związanych z badaną tkanką - w tym przypadku kostną. Charakterystycznymi genami będą na przykład te zawarte w badaniu :

- ***SOX9*** rozwój układu kostnego, różnicowanie chondrocytów
- ***MEF2A*** aktywacja genów indukowanych przez czynniki wzrostu oraz czynniki stresowe, wzrost komórek, apoptozę
- ***RUNX1*** hematopoeza

Szczególnie te, które już zostały zbadane w badaniu antycznego DNA - ***TFAP2A*** m. in. rozwój kończyn - ***NHLH1*** m. in. różnicowanie komórek

1.3.2 Wpływ na tezy historyczne

W przypadku znalezienia charakterystycznych różnic, będzie trzeba znacząco przeformułować niektóre tezy, w szczególności zmienić datowanie opisujące przejście pomiędzy okresem HG i AGR w okresie mezolitu, ponieważ metoda pozwoli nam na dokładniejsze określenie zmian.

1.3.3 Możliwe problemy

1.3.3.1 Znaczące różnice w epigenomach pomiędzy współczesnymi ludnościami autochtonicznymi oraz ludnością prehistoryczną

Może dojść do sytuacji, że różnice w DMS pomiędzy współczesnymi ludnościami autochtonicznymi i prehistorycznymi są na tyle duże, że nie znajdziemy żadnego przecięcia. Może to wynikać nie tylko z znaczących różnic środowiskowych, ale także z ewentualnych zanieczyszczeń. Trzeba by wtedy lepiej dobrać populację testową.

1.3.3.2 Różnice tkankowe między materiałem referencyjnym a kopalnym

Pierwszym istotnym problemem jest różnica tkankowa między materiałem referencyjnym a kopalnym. DMS (*differentially methylated site*) identyfikowane we współczesnej krwi byłyby następnie walidowane na DNA pozyskanym z kości, podczas gdy wzorce metylacji są silnie zależne od typu tkanki. Aby ograniczyć to ryzyko, analizę należy zawęzić do pozycji względnie stabilnych międzytkankowo, w tym potencjalnie do metastabilnych epialleli.

1.3.3.3 Reprezentatywność współczesnych populacji autochtonicznych

Drugie ograniczenie dotyczy reprezentatywności współczesnych populacji autochtonicznych jako modeli populacji prehistorycznych. Dzisiejsze grupy określane jako HG często przeszły kontakt kulturowy, zmiany diety, presję demograficzną oraz ekspozycje środowiskowe odmienne od tych, które charakteryzowały populacje pradziejowe. W konsekwencji nie mogą być traktowane jako wierne odpowiedniki dawnych łowców-zbieraczy, lecz jedynie jako przybliżone populacje referencyjne.

1.3.3.4 Czynniki konfundujące

Trzecim ryzykiem są konfundery związane z pochodzeniem genetycznym, klimatem, środowiskiem lokalnym oraz efektami technicznymi, takimi jak partia eksperymentalna. Sygnał interpretowany jako „HG vs. AGR” może w rzeczywistości odzwierciedlać strukturę populacyjną, lokalną historię demograficzną albo specyficzne warunki środowiskowe. Mitygacja tego problemu wymaga kontroli współzmiennych, uwzględnienia *cis-meQTL* oraz replikacji w wielu niezależnych parach populacji HG/AGR z różnych regionów geograficznych. (Inna genetyka populacji, a nie tylko epigenetyka)

1.3.3.5 Specyfika starożytnego DNA (aDNA)

Czwarta grupa ograniczeń wynika ze specyfiki starożytnego DNA. Deaminacja cytozyn, niskie pokrycie oraz fragmentacja cząsteczek mogą prowadzić do błędnej estymacji proporcji $C \rightarrow T$, a tym samym do fałszywie dodatnich DMR. Minimalnym zabezpieczeniem powinno być zastosowanie progu efektywnego pokrycia, na przykład ≥ 12 , wygładzanie sygnału w oknach genomowych oraz kontrola FDR oparta na permutacjach.

1.3.3.6 Kontaminacja współczesnym DNA

Kolejnym problemem jest kontaminacja współczesnym DNA, która może zaniżać lub zniekształcać rekonstruowany sygnał metylacji. Konieczna jest zatem walidacja profilu uszkodzeń, na przykład z użyciem *mapDamage*, oraz zastosowanie filtrów kontaminacji dostosowanych do typu materiału i jakości biblioteki.

1.3.3.7 Specyficzność typów komórek

Należy także uwzględnić specyficzność typów komórek. W przypadku krwi proporcje komórek immunologicznych silnie wpływają na profil metylacji, natomiast w kości sygnał może zależeć od składu komórkowego tkanki i stopnia remodelingu. Bez korekty składu komórkowego istnieje ryzyko, że wykryte różnice będą odzwierciedlały zmienność tkankową, a nie tryb życia.

1.3.3.8 Wymienność etykiet w testach permutacyjnych

Dodatkowym problemem jest wymienność etykiet w testach permutacyjnych. Jeżeli osobnicy różnią się nie tylko trybem życia, lecz także pochodzeniem, wiekiem próbki, regionem lub jakością zachowania DNA, losowe permutowanie etykiet HG/AGR może prowadzić do obciążonych wartości p . Permutacje powinny być zatem wykonywane w ramach bloków kontrolujących strukturę danych, na przykład region, okres chronologiczny, partię eksperymentalną lub poziom pokrycia.

1.3.3.9 Brak niezależnego złotego standardu (Ryzyko cyrkularności)

Wreszcie, metoda nie dysponuje niezależnym złotym standardem. Status HG/AGR populacji kopalnych pochodzi z interpretacji archeologicznej, czyli z tego samego typu informacji, który metoda miałaby częściowo uzupełniać lub weryfikować. Rodzi to ryzyko cyrkularności. Dlatego klasyfikacja epigenetyczna powinna być traktowana nie jako samodzielny dowód trybu życia, lecz jako dodatkowa warstwa informacji integrowana z archeologią, izotopami stabilnymi, paleogenomiką oraz kontekstem środowiskowym.

- [1] M. Fagny and et al., “The epigenomic landscape of african rainforest hunter-gatherers and farmers,” *Nature Communications*, vol. 6, p. 10047, 2015, doi: [10.1038/ncomms10047](https://doi.org/10.1038/ncomms10047).
- [2] A. W. Briggs *et al.*, “Removal of deaminated cytosines and detection of in vivo methylation in ancient DNA,” *Nucleic Acids Research*, vol. 38, no. 6, p. e87, 2010, doi: [10.1093/nar/gkp1163](https://doi.org/10.1093/nar/gkp1163).
- [3] D. Gokhman and et al., “Reconstructing the DNA methylation maps of the neandertal and the denisovan,” *Science*, vol. 344, no. 6183, pp. 523–527, 2014, doi: [10.1126/science.1250368](https://doi.org/10.1126/science.1250368).
- [4] A. Barouch and et al., “Reconstructing DNA methylation maps of ancient populations,” *Nucleic Acids Research*, vol. 52, no. 4, pp. 1602–1612, 2024, doi: [10.1093/nar/gkae010](https://doi.org/10.1093/nar/gkae010).
- [5] K. Hanghøj and et al., “Fast, accurate and automatic ancient nucleosome and methylation maps with epiPALEOMIX,” *Molecular Biology and Evolution*, vol. 33, no. 13, pp. 3284–3298, 2016, doi: [10.1093/molbev/msw183](https://doi.org/10.1093/molbev/msw183).
- [6] Y. Mathov, N. Rosen, C. Leibson, E. Meshorer, B. Yakir, and L. Carmel, “RoAM: Computational reconstruction of ancient methylomes and identification of differentially methylated regions,” *Genome Biology*, vol. 26, no. 1, 2025, doi: [10.1186/s13059-025-03702-7](https://doi.org/10.1186/s13059-025-03702-7).
- [7] Anonymous, “Inferring past environments from ancient epigenomes,” *BioRxiv*, 2017.
- [8] R. Vaisvila *et al.*, “Enzymatic methyl sequencing detects DNA methylation at single-base resolution from picograms of DNA,” *Genome Research*, vol. 31, no. 7, pp. 1280–1289, 2021, doi: [10.1101/gr.266551.120](https://doi.org/10.1101/gr.266551.120).
- [9] F. Krueger and S. R. Andrews, “Bismark: A flexible aligner and methylation caller for bisulfite-seq applications,” *Bioinformatics*, vol. 27, no. 11, pp. 1571–1572, 2011, doi: [10.1093/bioinformatics/btr167](https://doi.org/10.1093/bioinformatics/btr167).
- [10] B. S. Pedersen, K. Eyring, S. De, I. V. Yang, and D. A. Schwartz, “Fast and accurate alignment of long bisulfite-seq reads,” *arXiv preprint arXiv:1401.1129*, 2014, doi: [10.48550/arXiv.1401.1129](https://doi.org/10.48550/arXiv.1401.1129).
- [11] P. A. Ewels *et al.*, “The nf-core framework for community-curated bioinformatics pipelines,” *Nature Biotechnology*, vol. 38, no. 3, pp. 276–278, 2020, doi: [10.1038/s41587-020-0439-x](https://doi.org/10.1038/s41587-020-0439-x).
- [12] P. Ewels, M. Magnusson, S. Lundin, and M. Käller, “MultiQC: Summarize analysis results for multiple tools and samples in a single report,” *Bioinformatics*, vol. 32, no. 19, pp. 3047–3048, 2016, doi: [10.1093/bioinformatics/btw354](https://doi.org/10.1093/bioinformatics/btw354).

- [13] N. Rohland, S. Mallick, M. Mah, R. Maier, N. Patterson, and D. Reich, “Three assays for in-solution enrichment of ancient human DNA at more than a million SNPs,” *Genome Research*, vol. 32, no. 11–12, pp. 2068–2078, 2022, doi: [10.1101/gr.276728.122](https://doi.org/10.1101/gr.276728.122).
- [14] R. Davidson, X. Rocarada, *et al.*, “Optimized in-solution enrichment of over a million ancient human SNPs,” *Genome Biology*, vol. 26, no. 1, 2025, doi: [10.1186/s13059-025-03622-6](https://doi.org/10.1186/s13059-025-03622-6).
- [15] N. Rohland, I. Glocke, A. Aximu-Petri, and M. Meyer, “Extraction of highly degraded DNA from ancient bones, teeth and sediments for high-throughput sequencing,” *Nature Protocols*, vol. 13, no. 11, pp. 2447–2461, 2018, doi: [10.1038/s41596-018-0050-5](https://doi.org/10.1038/s41596-018-0050-5).
- [16] M. L. Carpenter *et al.*, “Pulling out the 1,” *The American Journal of Human Genetics*, vol. 93, no. 5, pp. 852–864, 2013, doi: [10.1016/j.ajhg.2013.10.002](https://doi.org/10.1016/j.ajhg.2013.10.002).
- [17] C. J. Adler *et al.*, “Sequencing ancient calcified dental plaque shows changes in oral microbiota with dietary shifts of the neolithic and industrial revolutions,” *Nature Genetics*, vol. 45, no. 4, pp. 450–455, 2013, doi: [10.1038/ng.2536](https://doi.org/10.1038/ng.2536).
- [18] W. Haak and *et al.*, “The arrival of siberian ancestry connecting the eastern baltic to uralic speakers,” *American Journal of Human Genetics*, 2015.
- [19] I. Olalde and *et al.*, “The beaker phenomenon and the genomic transformation of northwest europe,” *Nature*, vol. 555, pp. 190–196, 2018, doi: [10.1038/nature25738](https://doi.org/10.1038/nature25738).
- [20] I. Mathieson and *et al.*, “Genome-wide patterns of selection in 230 ancient eurasians,” *Nature*, vol. 528, no. 7583, pp. 499–503, 2015, doi: [10.1038/nature16152](https://doi.org/10.1038/nature16152).
- [21] I. Lazaridis and *et al.*, “The genetic history of the southern arc: A bridge between west asia and europe,” *Science*, vol. 377, no. 6609, p. eabm4247, 2022, doi: [10.1126/science.abm4247](https://doi.org/10.1126/science.abm4247).
- [22] A. Mittnik and *et al.*, “Kinship-based social inequality in bronze age europe,” *Science*, vol. 366, no. 6466, pp. 731–734, 2019, doi: [10.1126/science.aax6219](https://doi.org/10.1126/science.aax6219).
- [23] S. Horvath, “DNA methylation age of human tissues and cell types,” *Genome Biology*, vol. 14, no. 10, p. R115, 2013, doi: [10.1186/gb-2013-14-10-r115](https://doi.org/10.1186/gb-2013-14-10-r115).
- [24] V. M. Narasimhan and *et al.*, “Epigenetic clocks for ancient humans,” *Nature Ecology & Evolution*, vol. 7, 2023, doi: [10.1038/s41559-023-02116-2](https://doi.org/10.1038/s41559-023-02116-2).
- [25] H. Li and R. Durbin, “Fast and accurate short read alignment with burrows-wheeler transform,” *Bioinformatics*, vol. 25, no. 14, pp. 1754–1760, 2009, doi: [10.1093/bioinformatics/btp324](https://doi.org/10.1093/bioinformatics/btp324).
- [26] M. Meyer *et al.*, “A high-coverage genome sequence from an archaic denisovan individual,” *Science*, vol. 338, no. 6104, pp. 222–226, 2012, doi: [10.1126/science.1224344](https://doi.org/10.1126/science.1224344).
- [27] M. Schubert *et al.*, “Improving ancient DNA read mapping against modern reference genomes,” *BMC Genomics*, vol. 13, p. 178, 2012, doi: [10.1186/1471-2164-13-178](https://doi.org/10.1186/1471-2164-13-178).
- [28] H. Renaud G., “Gargammel: A sequence simulator for ancient DNA,” *Bioinformatics*, pp. 577–579, 2017.
- [29] Genome Reference Consortium, “Human genome reference assemblies.” 2026. Available: <https://www.ncbi.nlm.nih.gov/grc/human>
- [30] H. Feng, K. N. Conneely, and H. Wu, “A bayesian hierarchical model to detect differentially methylated loci from single nucleotide resolution sequencing data,” *Nucleic Acids Research*, vol. 42, no. 8, p. e69, 2014, doi: [10.1093/nar/gku154](https://doi.org/10.1093/nar/gku154).

- [31] M. D. Young, M. J. Wakefield, G. K. Smyth, and A. Oshlack, “Gene ontology analysis for RNA-seq: Accounting for selection bias,” *Genome Biology*, vol. 11, no. 2, p. R14, 2010, doi: [10.1186/gb-2010-11-2-r14](https://doi.org/10.1186/gb-2010-11-2-r14).