

IDMSpHGiAGR

Identyfikacja DMS pomiędzy HG i AGR

Grupa 4

2026-06-24

Table of contents

1	IDMSpHGiAGR - Identyfikacja DMS pomiędzy HG i AGR	1
1.1	Wstęp	1
1.1.1	Abstrakt / streszczenie	1
1.1.2	Cel naukowy	2
1.1.3	Aktualny stan wiedzy	2
1.2	Metodologia	4
1.2.1	Kohorty i liczba próbek	4
1.2.2	Mapy metylacyjne dla populacji współczesnych	4
1.2.3	Mapy metylacyjne dla populacji kopalnych	5
1.2.4	Symulacja DMS	8
1.2.5	Analiza DMS dla populacji współczesnych	8
1.2.6	Analiza DMS dla populacji kopalnych	9
1.3	Oczekiwane wyniki	11
1.3.1	Cechy charakterystyczne	11
1.3.2	Wpływ na tezy historyczne	11
1.3.3	Możliwe problemy	11

1 IDMSpHGiAGR - Identyfikacja DMS pomiędzy HG i AGR

1.1 Wstęp

1.1.1 Abstrakt / streszczenie

Projekt IDMSpHGiAGR ma na celu opracowanie nowej, niezależnej od artefaktów archeologicznych metody klasyfikacji prehistorycznych strategii utrzymania (łowców-zbieraczy [HG] vs. społeczności rolniczych [AGR]) na podstawie analizy porównawczej map metylacji DNA.

Pozycje różnicowo zmetylowane (DMS), wykazujące istotną statystycznie zależność ze zbiorami walidacyjnymi, zostaną zdefiniowane jako zestaw stabilnych ewolucyjnie markerów epigenetycznych.

1.1.2 Cel naukowy

Celem naukowym jest skonstruowanie nowej metody epigenetycznej umożliwiającej klasyfikację populacji prehistorycznych jako *hunter-gatherers* (HG) lub rolniczo-miejskich (AGR), niezależnej od artefaktów archeologicznych.

Metoda wykorzystywałaby scharakteryzowane modyfikacje epigenetyczne we współczesnych populacjach autochtonicznych HG i AGR zestawionych z ludnościami antycznymi.

1.1.3 Aktualny stan wiedzy

1.1.3.1 Metody rekonstrukcji map metylacji

1.1.3.1.1 Wykorzystane zjawisko - deaminacja cytozyn

Rekonstrukcja map metylacji z kopalnego DNA (aDNA) opiera się na zjawisku deaminacji cytozyn – dominującym procesie chemicznego rozkładu aDNA [1]. Niemetylowana cytozyna deaminuje do uracylu ($C \rightarrow U$), natomiast metylowana 5-metylocytozyna deaminuje do tyminy ($5mC \rightarrow T$). Tempo deaminacji jest silnie zależne od struktury fragmentu: w jednoniciowych cząsteczkach na końcach fragmentów sięga kilkudziesięciu procent, podczas gdy w częściach dwuniciowych wynosi około 1% lub mniej; uśredniony wskaźnik deaminacji fragmentu mieści się zwykle w przedziale 1–3%. Protokoły przygotowania bibliotek z (częściowym lub pełnym) traktowaniem USER / UDG (*Uracil-Specific Excision Reagent*) usuwają uracyl, ale nie naruszają tymin. Dzięki temu udział tymin na wyspach CpG (gdzie cytozyna jest metylowana w genomie ssaków), zwany wskaźnikiem $C \rightarrow T$, może służyć jako estymator przedśmiertnego poziomu metylacji.

Dla pozycji i definiuje się wskaźnik:

$$C \rightarrow T(i) = \frac{t_i}{t_i + c_i}$$

Gdzie t_i oraz c_i to liczby odczytów z tyminą i cytozyną na danej pozycji. Wyższy wskaźnik odpowiada wyższemu poziomowi metylacji. Ponieważ poziomy metylacji sąsiadujących CpG są silnie skorelowane (ko-metylacja w obrębie regionów rzędu ≈ 2 kpz), estymację wygładza się w przesuwym oknie obejmującym kilka–kilkadziesiąt kolejnych CpG, co radykalnie redukuje błąd standardowy estymatora.

1.1.3.1.2 Metoda oryginalna

Metoda oryginalna [2] dotyczyła pierwszej pełnej rekonstrukcji metylomu neandertalczyka i denisowianina. Wymaga próbek o wysokim pokryciu shotgun ($\geq 15\times$) poddanych traktowaniu USER. Porównanie z metylomami współczesnych ludzi pozwoliło zidentyfikować ≈ 2000 regionów różnicowo zmetylowanych (DMR), w tym istotne zmiany w klastrze *HOXD*, potencjalnie tłumaczące różnice anatomiczne między człowiekiem archaicznym a współczesnym. Ograniczeniem jest jednak dostępność danych: bardzo niewiele próbek aDNA spełnia jednocześnie oba wymagania — wystarczająco wysokie pokrycie oraz przygotowanie biblioteki z traktowaniem USER. W praktyce metodę zastosowano dotąd jedynie do nielicznych okazów (neandertalczyk, denisowianin oraz kilku anatomicznie współczesnych ludzi). ***

1.1.3.1.3 Adaptacja metody do danych o niskim pokryciu (Barouch i in., 2024, NAR)

Zdecydowana większość kopalnych osobników jest sekwencjonowana metodą hybrydizacyjnego wzbogacania (*in-solution capture*), najczęściej z użyciem panelu 1240K ($\approx 1,24$ mln SNP) – sekwencjonowanie tylko niewielkich fragmentów genomu, co daje dane zbyt płytkie do rekonstrukcji metylacji na poziomie pojedynczego osobnika. Autorzy [3] wykorzystują obserwację, że zmienność metylacji wewnątrz populacji jest mniejsza niż między populacjami – populacje mają więc charakterystyczne profile metylacyjne. Zamiast rekonstruować mapę indywidualną, łączą odczyty wielu osobników z tej samej populacji, uzyskując mapę metylacji reprezentatywną dla całej populacji. Kluczowe elementy procedury:

- **Naiwne łączenie (naive pulling)** – proste sumowanie liczników C i T w każdej pozycji CpG ze wszystkich osobników; działa równie dobrze lub lepiej niż wariant „zaawansowany” uwzględniający indywidualne tempa deaminacji (osobniki z tego samego miejsca i okresu przeszli zbliżone procesy deaminacji).
- **Filtrowanie** – usunięcie domniemanych duplikatów PCR oraz pozycji CpG o wskaźniku $C \rightarrow T > 0,25$ (prawdopodobnie mutacje, a nie deaminacja).
- **Mapowanie $C \rightarrow T$ na metylację** metodą *histogram matching* – nieliniowe dopasowanie histogramu wskaźników $C \rightarrow T$ do referencyjnego histogramu metylacji we współczesnej kości człowieka (WGBS).
- **Adaptacyjny rozmiar okna** – do 31 kolejnych CpG, dobierany w zależności od efektywnego pokrycia kohorty.
- **Próg jakości** – do wiarygodnej rekonstrukcji potrzebne jest efektywne pokrycie ≥ 12 (najlepiej > 15). Efektywne pokrycie kohorty można z góry oszacować modelem liniowym z liczby osobników i średniej liczby trafień w autosomalne SNP (*single-nucleotide polymorphism*).

Panel 1240K nie jest połączenie dwóch wcześniejszych paneli wzbogacania opracowanych w laboratorium Davida Reicha (Harvard) we współpracy z grupą Nicka Pattersona i innymi. Stąd bywa nazywany „Reich panel”. Jest używany, ponieważ w kopalnych kościach/zębach DNA endogenne (ludzkie) to często $< 1\%$ całego materiału, pozostała część to bakterie glebowe, grzyby, zanieczyszczenia.

Walidacja wykazała, że zrekonstruowane mapy populacyjne odtwarzają oczekiwane cechy biologiczne: hipometylację wysp CpG i promotorów genów *housekeeping*, wysoką metylację elementów Alu, a także najsilniejszą korelację z metylomem osteoblastów (zgodnie ze szkieletowym pochodzeniem aDNA). Detekcję DMR między populacjami przeprowadza się z kontrolą odsetka fałszywych odkryć (FDR – *false discovery rate*) poprzez permutacje etykiet populacyjnych.

1.1.3.1.4 Narzędzia obliczeniowe

Podejście łączenia [3] jest dla nas kluczowe: umożliwia uzyskanie populacyjnych map metylacji z tysięcy już dostępnych, niskopokryciowych próbek 1240K – w tym z populacji bezpośrednio związanych z przejściem HG $\rightarrow$ AGR (np. brytyjski neolit i epoka brązu, kultura pucharów dzwonowatych). Pozwala to prowadzić porównania HG vs. AGR na poziomie populacji, mimo że pojedyncze próbki są zbyt płytkie do klasycznej rekonstrukcji metylomu. Do zautomatyzowanego przetwarzania wykorzystuje się potoki takie jak epiPALEOMIX [4] oraz RoAM [5].

1.1.3.1.5 Cechy epigenetyczne w ludnościach autochtonicznych

#TODO przepisać i przenieść bibliografie Aktualnie wykazano, że istnieje istotna różnica pomiędzy metylacją w populacjach HG i AGR oraz scharakteryzowano, że jest to związane z regulacją immunologiczną oraz rozwojem [6]. Badania jednak były wykonane na komórkach krwi.

1.1.3.1.6 Analizy wykorzystujące metylacje

Aktualnie wykorzystano metylację do scharakteryzowania różnic w mapach metylacyjnych u Neandertalczyków oraz Denisovian [2] oraz zidentyfikowano ERLs związane z głodem i stwierdzono, że w populacjach HG występowały trendy zmian o charakterze adaptacyjnym [7]. Nie zidentyfikowano jednak charakterystycznych czynników epigenetycznych różnicujących grupy HG i AGR na poziomie tkanki kostnej.

1.2 Metodologia

1.2.1 Kohorty i liczba próbek

Szczegółowy podział kohort referencyjnych i walidacyjnych znajduje się w dedykowanym [arkuszu danych](#).

1.2.2 Mapy metylacyjne dla populacji współczesnych

1.2.2.1 Wstęp

Celem tej części metodologii jest wygenerowanie genomowych map metylacji DNA dla współczesnych kohort referencyjnych o jednoznacznym trybie życia: populacji łowiecko-zbierackich (HG) oraz rolniczych (AGR). Mapy te stanowią sygnaturę odniesienia do wyodrębnienia komponentu epigenetycznego związanego z trybem życia oraz punkt kalibracyjny dla map rekonstruowanych z materiału kopalnego. Zgodnie z założeniem rozszerzenia analizy poza pojedynczą parę populacji afrykańskich [6], profilowanie obejmuje wiele niezależnych par HG/AGR z różnych kontynentów i stref klimatycznych, co zwiększa moc statystyczną i pozwala oddzielić uniwersalny efekt trybu życia od lokalnych uwarunkowań genetycznych, demograficznych i środowiskowych.

Uwaga metodologiczna: w odróżnieniu od Fagny i in. [6] gdzie dane pochodzą z mikromacierzy (Illumina 450K, wartości β), aby uzyskać rozdzielczość pojedynczego CpG w skali całego genomu, wybrano enzymatyczne sekwencjonowanie metylacji (EM-seq), zapewniające profilowanie całogenomowe [8].

1.2.2.2 Procedura

1.2.2.2.1 Pozyskanie materiału i ekstrakcja DNA

Materiałem referencyjnym jest współczesna tkanka kostna (kość zbita lub część skalista kości skroniowej — *petrous bone*) ze współczesnego materiału szkieletowego/sekcyjnego. Wybór tkanki kostnej, a nie krwi obwodowej zastosowanej w oryginalnej analizie referencyjnej [6], wynika z silnej tkankowej specyficzności metylacji DNA: mapy współczesne muszą pochodzić z tej samej tkanki co kopalne aDNA (materiał szkieletowy), aby porównanie HG vs. AGR nie było obciążone różnicą typu tkanki. Ze względu na heterogeniczność komórkową tkanki kostnej (osteoblasty, osteocyty, osteoklasty, domieszka szpiku) równolegle szacuje się skład komórkowy próbki do późniejszej korekty. Wyizolowane DNA kontroluje się pod kątem ilości i integralności, a masę wejściową dobiera zgodnie z protokołem przygotowania bibliotek EM-seq [8].

1.2.2.2.2 Konwersja enzymatyczna i przygotowanie bibliotek (EM-seq)

EM-seq rozróżnia cytozyny metylowane i niemetylowane w dwóch krokach enzymatycznych zamiast chemicznej konwersji dwusiarczynowej [8]. Najpierw enzymy z rodziny TET (TET2) wraz z utleniaczem chronią 5-metylocytozynę (5mC) i 5-hydroksymetylocytozynę przed deaminacją, następnie deaminaza APOBEC deaminuje wyłącznie niemodyfikowane cytozyny do uracyli. Po amplifikacji i sekwencjonowaniu pozycje niemetylowane odczytywane są jako tymina (T), a metylowane pozostają cytozyną (C) — sygnał analogiczny do metody dwusiarczynowej, lecz przy łagodniejszej obróbce DNA i wyższej wydajności mapowania oraz pokrycia [8].

1.2.2.2.3 Mapowanie i budowa macierzy zliczeń CpG

Surowe odczyty poddaje się kontroli jakości oraz przycinaniu adapterów i zasad o niskiej jakości (**FastQC**, **fastp**), a następnie mapuje do ludzkiego genomu referencyjnego (GRCh38) programem uwzględniającym konwersję (**Bismark** lub **BWA-Meth**) w ramach potoku **nf-core/methylseq** [9], [10], [11]. Wybór GRCh38 zapewnia spójność współrzędnych z mapami kopalnymi. Pliki BAM sortuje się, indeksuje i oczyszcza z duplikatów PCR (**samtools**), a zbiorcze raporty jakości agreguje **MultiQC** [12]. Sygnał metylacji ekstrahuje się na poziomie pojedynczych pozycji CpG (**MethylDackel** lub moduł **Bismark**), uzyskując liczbę odczytów metylowanych i niemetylowanych [9]. Komplementarne pomiary z obu nici łączy się (*strand merging*), a pozycje o pokryciu poniżej progu odrzuca. Wynikiem jest macierz zliczeń CpG (poziom metylacji wraz z pokryciem) stanowiąca właściwą mapę metylacji.

1.2.2.2.4 Filtrowanie pozycji i kontrola jakości

Z macierzy usuwa się pozycje pokrywające się ze znanymi polimorfizmami pojedynczego nukleotydu (maskowanie SNP) oraz regiony problematyczne (*blacklist*), ponieważ wariant genetyczny w miejscu CpG może imitować zmianę stanu metylacji; wpływ pochodzenia genetycznego kontroluje się przez niezależne genotypowanie osobników [6]. Następnie koryguje się dwie kluczowe zmienne zakłócające — heterogeniczność składu komórkowego (proporcje typów komórek tkanki kostnej) oraz wiek osobnika [6]. Przed przekazaniem map do detekcji DMS przeprowadza się eksploracyjną kontrolę jakości (rozkład pokrycia i globalnych poziomów metylacji, PCA/MDS, grupowanie próbek, efekty wsadowe) oraz weryfikuje wydajność konwersji enzymatycznej (kontrola λ /pUC19); próbki odstające lub o niewystarczającej jakości są odrzucane [8].

1.2.3 Mapy metylacyjne dla populacji kopalnych

1.2.3.1 Wstęp

Celem tej części metodologii jest odtworzenie populacyjnych map metylacji dla kopalnych kohort walidacyjnych o jednoznacznym trybie życia, czyli dla grup *zbieracko-łowieckich* (*HG*) oraz *rolniczych* (*AGR*), oraz dla populacji niejednoznacznych, między innymi Çatalhöyük.

Mapy te dostarczają wartości m^j wykorzystywanych później w teście klasyfikacyjnym. Ponieważ pojedyncze próbkimają zbyt niskie pokrycie do rekonstrukcji indywidualnej [13], [14], mapy budujemy na poziomie populacji, łącząc odczyty wielu osobników z tej samej kohorty. Mapy posłużą potem do walidacji metody.

Choć Çatalhöyük jest zwykle klasyfikowane jako osiedle rolnicze (*AGR*), jest przejściowe / niejednoznaczne pod względem strategii bytowania.

1.2.3.2 Procedura

Proces przetwarzania danych obejmuje ekstrakcję sygnału deaminacji, filtrowanie artefaktów, nieliniowe dopasowanie histogramów oraz wygładzanie sygnału metodą okien przesuwnych zgodnie z podejściem zaimplementowanym w pakietach referencyjnych [3], [5]. Poniżej opisano kolejne kroki potoku — od doboru kohort, przez przygotowanie danych sekwencyjnych i właściwą rekonstrukcję metylacji, po detekcję regionów różnicowo zmetylowanych — zachowując analogiczną strukturę względem części dotyczącej populacji współczesnych.

1.2.3.2.1 Przygotowanie bibliotek aDNA: Ekstrakcja i konwersja

Procedura laboratoryjna przygotowania materiału kostnego oraz izolacji kopalnego DNA (aDNA) opiera się na protokole, który został opisany w [15], co pozwala na zminimalizowanie ryzyka kontaminacji współczesnym materiałem biologicznym. Proces ten obejmuje następujące kroki:

1. **Dekontaminacja powierzchniowa i pobranie próby:** W kroku tym z zewnętrznej warstwy tkanki kostnej zostaje usunięte egzogenne DNA. Następnie z warstwy o najwyższej gęstości osteocytów wywierca się od 50 do 100 mg drobnego proszku kostnego, co pozwala maksymalnie zwiększyć stężenie endogenego aDNA.
2. **Liza i trawienie enzymatyczne:** Uzyskany proszek kostny zostaje zawieszony w buforze ekstrakcyjnym zawierającym EDTA oraz Proteinazę K. Pozwala to na rozpuszczenie matrycy kości i uwolnienie uwięzionych w niej cząsteczek kwasów nukleinowych.
3. **Wiązanie i oczyszczanie na kolumnach krzemionkowych:** W kroku tym zostaje wyemitowane czyste aDNA.
4. **Przygotowanie bibliotek sekwencyjnych (Konwersja):** Wyizolowane aDNA zostaje poddane procedurze ligacji specyficznych adapterów sekwencyjnych w formacie single-stranded (ssDNA) lub double-stranded (dsDNA) [15]. Proces konwersji przygotowuje uszkodzone cząsteczki do wydajnej amplifikacji PCR, nadając im unikalne indeksy identyfikujące próbki.

1.2.3.2.2 Wzbogacona hybrydyzacja in-solution (Twist Ancient DNA)

W kopalnych próbach kostnych endogenne aDNA stanowi zazwyczaj jedynie niewielki ułamek całkowitego wyekstrahowanego DNA (wyekstrahowane DNA $\leq 10\%$) [13], [16], w którym dominują cząsteczki pochodzenia środowiskowego, takie jak DNA bakterii i grzybów glebowych [16], [17]. Aby rozwiązać problem niskiej zawartości matrycy, usunąć zanieczyszczenia mikrobiologiczne i uzyskać czyste dane o wysokiej specyficzności, w procesie tym zastosujemy technologię wzbogacania ukierunkowanego (*target enrichment*) w układzie *in-solution capture* przy użyciu dedykowanej platformy Twist Ancient DNA [13]. Metoda ta pozwala na wybiórcze wyłapanie ludzkich cząsteczek, co w przypadku bardzo słabo zachowanych próbek zwiększa frakcję DNA endogenego wielokrotnie w stosunku do sekwencjonowania bezpośredniego (shotgun), drastycznie zmniejszając tło sekwencyjne generowane przez organizmy egzogenne [13].

Fizykochemia tego procesu oraz mechanizm selekcji opierają się na następujących założeniach: - **Fizyczna struktura sond i komplementarność:** Stosujemy sondy RNA, których sekwencja jest ściśle komplementarna do docelowych, ludzkich regionów genomowych [14]. W kolejnym etapie, po denaturacji cieplnej biblioteki DNA, sondy hybrydują z komplementarnymi cząsteczkami aDNA. Kompleksy sonda-aDNA są następnie fizycznie wyłapywane z roztworu, natomiast nieskomplementowane DNA środowiskowe zostaje całkowicie wymyte. Należy podkreślić, że technologia ta eliminuje kontaminację mikrobiologiczną, lecz nie usuwa zanieczyszczeń współczesnym DNA ludzkim; ich detekcja zachodzi na drodze bioinformatycznej. - **Wpływ degradacji aDNA na długość odczytów:** Po zmapowaniu odczytów do genomu referencyjnego, uzyskuje się fragmenty pokrywające pozycję docelową (SNP) wraz z jej bezpośrednim otoczeniem, pokrywające region o długości maksymalnie około 80-100 bp wokół pozycji docelowej [13].

- **Charakterystyka funkcjonalna celów genomowych:** Wybrane sondy zostały zaprojektowane tak, aby celować w kluczowe pod względem ewolucyjnym i funkcjonalnym obszary ludzkiego genomu [13]. Struktura paneli obejmuje następujące komponenty:
 1. *Komponent populacyjny (Rdzeń 1240K)* Kluczowe dla rekonstrukcji historycznych migracji, demografii oraz pokrewieństwa [18], [19].
 2. *Regiony kodujące i regulatorowe (Zawartość fenotypowa)* Lokusy powiązane bezpośrednio z ekspresją cech fizycznych, wyselekcjonowane z baz [20]. Pozwala to na bezpośrednią analizę funkcjonalnych zmian adaptacyjnych w sekwencjach kodujących białka oraz w regionach promotorowych i enhancerowych.
 3. *Regiony konserwatywne i epigenetyczne* Obszary HAR (*Human Accelerated Regions*) oraz pozycje metylacyjne służące do analizy epigenetycznego starzenia się tkanek i rekonstrukcji starożytnych metylomów [21], [22], co koresponduje z modelami epigenetycznymi opracowanymi dla populacji kopalnych i współczesnych [2], [3], [6].

1.2.3.2.3 Wstępne przetwarzanie odczytów i mapowanie do genomu referencyjnego

Surowe odczyty kopalnych bibliotek poddaje się kontroli jakości i przycinaniu adapterów (**FastQC**, **fastp**), a następnie mapuje do ludzkiego genomu referencyjnego (GRCh38). Należy uwzględnić, że odczyty aDNA są **bardzo krótkie**, co utrudnia jednoznaczne mapowanie, ponieważ krótkie odczyty częściej dopasowują się wieloznacznie, szczególnie w regionach powtarzalnych. Z tego powodu w analizie aDNA standardem jest program mapujący **bwa aln/samse** (BWA-backtrack) [23], który lepiej radzi sobie z krótkimi i uszkodzonymi odczytami niż **bwa mem** (zaprojektowany dla odczytów $> \approx 70$ pz) [24]. Dodatkowo odrzuca się odczyty krótsze niż ~ 30 – 35 pz, stosuje filtr jakości mapowania (MAPQ) oraz rozluźnia parametry dopasowania lub przeskalowuje oceny jakości poszczególnych zasad (np. programem **mapDamage**), aby uwzględnić niedopasowania wynikające z deaminacji na końcach fragmentów [25]. Zastosowanie sond panelu Twist łagodzi ten problem, ponieważ sondy celują w unikatowe, dobrze zdefiniowane loci wokół SNP (~ 100 pz), do których nawet krótkie odczyty mapują się względnie jednoznacznie. Powstałe pliki BAM sortuje się, indeksuje oraz oczyszcza z duplikatów PCR przy użyciu **samtools**, a wynik można skontrolować wizualnie w przeglądarce **IGV** [4], [5]. Wyniki te są zapisywane w postaci plików **bam**, **bai**.

1.2.3.2.4 Globalna ocena jakości i autentykacja próbek kopalnych

Po przeprowadzeniu sekwencjonowania wysokoprzepustowego (NGS) i wstępnego zmapowania, surowe dane w formacie BAM zostają poddane rygorystycznej procedurze filtracji całogenomowej w celu odrzucenia osobników o niskiej jakości lub wykazujących krytyczny poziom współczesnych zanieczyszczeń:

1. **Weryfikacja frakcji endogennej:** W kroku tym ocenia się ogólny stopień zachowania próby poprzez wyznaczenie stosunku odczytów mapujących się do ludzkiego genomu referencyjnego (GRCh38) do całkowitej liczby uzyskanych sekwencji [4]. Próbkę charakteryzującą się zbyt niską frakcją odczytów endogennych, wynikającą z przewagi tła środowiskowego (DNA mikroorganizmów glebowych), zostają bezwzględnie odrzucone z dalszych etapów obliczeniowych [16], [17].
2. **Kwantyfikacja kontaminacji współczesnym DNA ludzkim:** W kroku tym szacuje się poziom zanieczyszczenia współczesnym ludzkim DNA [2], [3]. W przypadku osobników płci męskiej analizuje się poziom heterozygotyczności na chromosomie X, natomiast dla całej kohorty bada się polimorfizm DNA mitochondrialnego. Dane te są procesowane za pomocą pakietów przeznaczonych do weryfikacji czystości starożytnych genomów [5]. Próbkę, w której oszacowany poziom kontaminacji współczesnym ludzkim DNA przekracza próg tolerancji ($> 1 - 3\%$), zostają usunięte z ostatecznej kohorty.

1.2.4 Symulacja DMS

1.2.4.1 Wstęp

Dla porównania skuteczności, zostanie dodatkowo przeprowadzona analiza wykorzystująca sztucznie zanieczyszczone i pofragmentowane sekwencje współczesne, symulujące aDNA. Dzięki temu sprawdzimy, czy wybrane przez nas parametry do analizy dają wiarygodne wyniki. Pomoże nam to również ustalić, z jakiego zakresu czasowego mogą pochodzić analizowane w ten sposób szczątki.

1.2.4.2 Procedura

1.2.4.2.1 Przygotowanie danych

Całość procesu symulacji zanieczyszczenia danych opiera się na wykorzystaniu opcji dostępnych w narzędziu gargammel [26], które zostało zaprojektowane właśnie do symulowania danych antycznych.

1. Sekwencje ludzkie będą pobrane z bazy NIH [27].
2. Zostaną one podzielone na fragmenty wielkości 30-80 par zasad.
3. Dodamy sekwencje egzogenne pochodzenia bakteryjnego, odpowiadające mikroorganizmom charakterystycznym dla tych znajdujących w szczątkach badanego rejonu geograficznego.
4. Dodane również zostaną charakterystyczne uszkodzenia zachodzące w procesie degradacji DNA post mortem.

1.2.4.2.2 Analiza bioinformatyczna

Przygotowane dane zostaną poddane ocenie jakości przy wykorzystaniu programu FastQC. Ewentualne filtrowanie i przycinanie sekwencji o zbyt niskiej jakości zostanie przeprowadzone wykorzystując program fastp. Odczyty zostaną zmapowane do genomu referencyjnego człowieka (GRCh37/hg19) programem BWA. Obce sekwencje usunięte zostaną narzędziem BlobTools.

1.2.5 Analiza DMS dla populacji współczesnych

1.2.5.1 Wstęp

Dotychczasowa charakterystyka różnic epigenetycznych między populacjami (HG) a (AGR) opiera się przede wszystkim na analizie jednej pary populacji z jednego regionu: afrykańskich łowców-zbieraczy lasu deszczowego oraz sąsiadujących z nimi rolników [6].

Jednakowoż, mała liczba niezależnych populacji ogranicza moc statystyczną i wiarygodność identyfikowanych miejsc różnicowo metylowanych (DMS), a różnice obserwowane między jedną parą HG/AGR mogą być zaburzone przez pochodzenie genetyczne, lokalną historię demograficzną oraz specyfikę środowiska, w tym klimat lasu równikowego [6].

Rozwiązaniem tego problemu jest włączenie wielu niezależnych par HG/AGR pochodzących z różnych kontynentów i stref klimatycznych.

1.2.5.2 Procedura

1.2.5.2.1 Identyfikacja miejsc różnicowo zmetylowanych (DMS)

Dane EM-seq (liczba odczytów metylowanych i niemetylowanych w każdej pozycji CpG) modelujemy testem opartym na rozkładzie beta-dwumianowym, uwzględniającym zmienność biologiczną i pokrycie (pakiet DSS) [28], porównując średni poziom metylacji między dwiema populacjami (HG vs. AGR) testem Walda. Zmienne zakłócające: płeć, wiek, proporcje typów komórek, w analizie referencyjnej wprowadzane jako współzmiennie [6], ograniczamy przed testem przez dopasowanie i stratyfikację próbek. Wartości P koryguje się metodą Benjamini-Hochberga; za DMS uznaje się pozycje o $P < 0,01$ oraz różnicy poziomu metylacji ($\Delta\beta$) ponad 10% [6]. Istotność nakładania się zestawów DMS ocenia się ponownym próbkowaniem, uwzględniając korelację w regionach ~2000 bp [6].

1.2.5.2.2 Analiza funkcjonalna i ontologia genów

Geny zawierające co najmniej jeden DMS poddaje się analizie nadreprezentacji kategorii ontologii genów (GO) pakietem goseq [6], [29]; jako miarę obciążenia detekcji stosujemy liczbę pozycji CpG o wystarczającym pokryciu na gen. Kategorię GO uznaje się za istotnie wzbogaconą dla wartości $P \leq 0,05$ [6].

1.2.6 Analiza DMS dla populacji kopalnych

1.2.6.1 Wstęp

Rekonstrukcja stanów metylacji dla populacji antycznych opiera się na specyficznych właściwościach degradacji post-mortem, umożliwiając binarne określenie statusu epigenetycznego zachowanych loci [1], [2]. Ze względu na unikalną architekturę danych uzyskiwanych z paneli wzbogacanych, potok analityczny nie dąży do wyznaczenia ciągłych wartości ilościowych, lecz ma na celu precyzyjne określenie, czy dany region genomowy był metylowany [3], [5]. Uzyskane w ten sposób profile epigenetyczne starożytnych próbek podlegają bezpośredniemu mapowaniu i porównaniu z referencyjnymi obszarami DMS zidentyfikowanymi u populacji współczesnych, co pozwala na uchwycenie specyficznych zmian ewolucyjnych związanych z trybem życia.

W celu porównania skuteczności i czułości potoku interpretacji epigenetycznej, cała procedura analityczna zostaje równolegle przeprowadzona zarówno dla autentycznych próbek kopalnych, jak i dla syntetycznych zbiorów danych. Przetwarzanie obu tych kohort (prawdziwej i symulowanej) przebiega w sposób identyczny na poziomie plików BAM oczyszczonych z duplikatów sekwencyjnych.

1.2.6.2 Procedura

1.2.6.2.1 Ekstrakcja sygnału metylacji (wskaźnik C $\rightarrow$ T)

Wejściowy sygnał metylacji odzyskuje się bezpośrednio ze specyficznego wzorca deaminacji, będącego dominującym procesem chemicznej degradacji starożytnego DNA [1]. Podczas uszkodzeń post-mortem, niemetylowana cytozyna deaminuje do uracylu, natomiast metylowana 5-metylocytozyna deaminuje do tyminy [1]. Na etapie przygotowania bibliotek stosujemy traktowanie enzymem USER, więc fragmenty zawierające uracyl, pochodzący z pozycji niemetylowanych, zostają wykluczone z sekwencjonowania [5]. W rezultacie, odczytane tyminy w pozycjach CpG reprezentują wyłącznie pozycje pierwotnie metylowane przed śmiercią osobnika, które uniknęły działania enzymu [5]. Wyższy wskaźnik bezpośrednio odpowiada wyższemu poziomowi metylacji przedśmiertnej [2], [3].

1.2.6.2.2 Filtrowanie pozycji CpG

Z dalszej analizy usuwa się pozycje niewiarygodne dla matematycznej rekonstrukcji mapy epigenetycznej [3], [5]: - **Pozycje o anomalnie wysokim pokryciu (Extreme Coverage)** — loci wykazujące nienaturalnie wysoką głębokość pokrycia odczytami. W procesie tym próg odcięcia wyznaczany jest automatycznie, co pozwala wyeliminować fałszywy sygnał pochodzący ze złego mapowania w regionach duplikacji segmentalnych i powtórzeń genomu [5]. - **Domniemane mutacje $C \rightarrow T$** — pozycje, w których wskaźnik $C \rightarrow T$ przekracza sztywny próg (np. $> 0,25$), co może indykować mutację genetyczną, a nie modyfikację epigenetyczną [5].

1.2.6.2.3 Estymacja tempa deaminacji

Globalne lub lokalne tempo deaminacji estymuje się na podstawie pozycji CpG.

1.2.6.2.4 Pulowanie osobników i rekonstrukcja mapy populacyjnej

Ponieważ pojedyncze próbki wzbogacane panelem docelowym mają często zbyt niskie indywidualne pokrycie dla samodzielnej rekonstrukcji, binarną mapę stanów buduje się na poziomie całej populacji poprzez pulowanie (łączenie) odczytów wielu osobników [3]: - **Łączenie naiwne** - polega na prostym sumowaniu liczników C i T w każdej pozycji CpG bezpośrednio ze wszystkich osobników wchodzących w skład danej kohorty [3]. - **Mapowanie wskaźnika $C \rightarrow T$ na metylację** - realizowane metodą dopasowywania histogramów (*histogram matching*), polegającą na nieliniowym dopasowaniu uzyskanych wskaźników $C \rightarrow T$ do referencyjnego histogramu metylacji ludzkiej tkanki kostnej [5]. - **Wygladzanie w przesuwym oknie** - proces rekonstrukcji prowadzi się w zdefiniowanym oknie W obejmującym kolejne pozycje CpG [5].

1.2.6.2.5 Kontrola efektywnego pokrycia

Wiarygodna i stabilna rekonstrukcja stanów metylacji na poziomie populacyjnym wymaga zachowania **efektywnego pokrycia na poziomie ≥ 12** [3]. Efektywne pokrycie kohorty można oszacować matematycznie z góry za pomocą modelu regresji liniowej, przyjmując jako zmienne liczbę pulowanych osobników oraz ich średnią liczbę unikalnych trafień w autosomalne loci SNP ($R^2 = 0,99$ w modelach referencyjnych) [3].

1.2.6.2.6 Mapowanie i porównanie profili metylacji z referencją współczesną

Uzyskane populacyjne mapy stanów metylacji dla kohort kopalnych (zarówno dla danych autentycznych, jak i zbiorów symulowanych) zostają poddane procedurze nakładania przestrzennego z ilościowymi macierzami referencyjnymi zidentyfikowanymi u ludności współczesnej [3]. Algorytm mapuje binarne stany metylacji kopalnych pozycji CpG bezpośrednio na współrzędne genomowe uniwersalnych miejsc różnicowo metylowanych (DMS), dla współczesnych populacji łowców-zbieraczy oraz rolników [5]. Pozwala to na precyzyjne określenie statusu epigenetycznego starożytnych kohort w oknach funkcjonalnych i identyfikację, które cechy metylacji specyficzne dla danego trybu życia były już utrwalone w badanych okresach historycznych [3].

1.2.6.2.7 Walidacja biologiczna i ewolucyjna map

Poprawność merytoryczną zrekonstruowanych map starożytnych weryfikuje się poprzez kontrolę obecności uniwersalnych cech biologicznych: głębokiej hipometylacji wysp CpG oraz promotorów genów metabolizmu podstawowego (*housekeeping genes*), podwyższonej metylacji elementów powtarzalnych, a także najwyższej korelacji ze współczesnymi referencyjnymi metylomami komórek tkanki kostnej [3]. Zweryfikowane pod kątem ewolucyjnym i strukturalnym profile metylacji służą jako niezależny układ odniesienia, umożliwiając ocenę stopnia ciągłości epigenetycznej oraz kierunku zmian funkcjonalnych w genomie ludzkim na przestrzeni dziejów, bez ryzyka zaburzenia wyników przez pośmiertną degradację próby [3], [5].

1.3 Oczekiwane wyniki

1.3.1 Cechy charakterystyczne

Możemy się spodziewać wykrycia cech związanych z badaną tkanką - w tym przypadku kostną. Charakterystycznymi genami będą na przykład te zawarte w badaniu :

- **SOX9** rozwój układu kostnego, różnicowanie chondrocytów
- **MEF2A** aktywacja genów indukowanych przez czynniki wzrostu oraz czynniki stresowe, wzrost komórek, apoptozę
- **RUNX1** hematopoeza

Szczególnie te, które już zostały zbadane w badaniu antycznego DNA - **TFAP2A** m. in. rozwój kończyn - **NHLH1** m. in. różnicowanie komórek

1.3.2 Wpływ na tezy historyczne

W przypadku znalezienia charakterystycznych różnic, będzie trzeba znacząco przeformułować niektóre tezy, w szczególności zmienić datowanie opisujące przejście pomiędzy okresem HG i AGR w okresie mezolitu, ponieważ metoda pozwoli nam na dokładniejsze określenie zmian.

1.3.3 Możliwe problemy

1.3.3.1 Znaczące różnice w epigenomach pomiędzy współczesnymi ludnościami autochtonicznymi oraz ludnością prehistoryczną

Może dojść do sytuacji, że różnice w DMS pomiędzy współczesnymi ludnościami autochtonicznymi i prehistorycznymi są na tyle duże, że nie znajdziemy żadnego przecięcia. Może to wynikać nie tylko z znaczących różnic środowiskowych, ale także z ewentualnych zanieczyszczeń. Trzeba by wtedy lepiej dobrać populację testową.

1.3.3.2 Reprezentatywność współczesnych populacji autochtonicznych

Drugie ograniczenie dotyczy reprezentatywności współczesnych populacji autochtonicznych jako modeli populacji prehistorycznych. Dzisiejsze grupy określane jako HG często przeszły kontakt kulturowy, zmiany diety, presję demograficzną oraz ekspozycje środowiskowe odmienne od tych, które charakteryzowały populacje pradziejowe. W konsekwencji nie mogą być traktowane jako wierne odpowiedniki dawnych łowców-zbieraczy, lecz jedynie jako przybliżone populacje referencyjne.

- [1] A. W. Briggs *et al.*, "Removal of deaminated cytosines and detection of in vivo methylation in ancient DNA," *Nucleic Acids Research*, vol. 38, no. 6, p. e87, 2010, doi: [10.1093/nar/gkp1163](https://doi.org/10.1093/nar/gkp1163).
- [2] D. Gokhman and et al., "Reconstructing the DNA methylation maps of the neandertal and the denisovan," *Science*, vol. 344, no. 6183, pp. 523–527, 2014, doi: [10.1126/science.1250368](https://doi.org/10.1126/science.1250368).
- [3] A. Barouch and et al., "Reconstructing DNA methylation maps of ancient populations," *Nucleic Acids Research*, vol. 52, no. 4, pp. 1602–1612, 2024, doi: [10.1093/nar/gkae010](https://doi.org/10.1093/nar/gkae010).
- [4] K. Hanghøj and et al., "Fast, accurate and automatic ancient nucleosome and methylation maps with epiPALEOMIX," *Molecular Biology and Evolution*, vol. 33, no. 13, pp. 3284–3298, 2016, doi: [10.1093/molbev/msw183](https://doi.org/10.1093/molbev/msw183).

- [5] Y. Mathov, N. Rosen, C. Leibson, E. Meshorer, B. Yakir, and L. Carmel, “RoAM: Computational reconstruction of ancient methylomes and identification of differentially methylated regions,” *Genome Biology*, vol. 26, no. 1, 2025, doi: [10.1186/s13059-025-03702-7](https://doi.org/10.1186/s13059-025-03702-7).
- [6] M. Fagny and et al., “The epigenomic landscape of african rainforest hunter-gatherers and farmers,” *Nature Communications*, vol. 6, p. 10047, 2015, doi: [10.1038/ncomms10047](https://doi.org/10.1038/ncomms10047).
- [7] Anonymous, “Inferring past environments from ancient epigenomes,” *BioRxiv*, 2017.
- [8] R. Vaisvila *et al.*, “Enzymatic methyl sequencing detects DNA methylation at single-base resolution from picograms of DNA,” *Genome Research*, vol. 31, no. 7, pp. 1280–1289, 2021, doi: [10.1101/gr.266551.120](https://doi.org/10.1101/gr.266551.120).
- [9] F. Krueger and S. R. Andrews, “Bismark: A flexible aligner and methylation caller for bisulfite-seq applications,” *Bioinformatics*, vol. 27, no. 11, pp. 1571–1572, 2011, doi: [10.1093/bioinformatics/btr167](https://doi.org/10.1093/bioinformatics/btr167).
- [10] B. S. Pedersen, K. Eyring, S. De, I. V. Yang, and D. A. Schwartz, “Fast and accurate alignment of long bisulfite-seq reads,” *arXiv preprint arXiv:1401.1129*, 2014, doi: [10.48550/arXiv.1401.1129](https://doi.org/10.48550/arXiv.1401.1129).
- [11] P. A. Ewels *et al.*, “The nf-core framework for community-curated bioinformatics pipelines,” *Nature Biotechnology*, vol. 38, no. 3, pp. 276–278, 2020, doi: [10.1038/s41587-020-0439-x](https://doi.org/10.1038/s41587-020-0439-x).
- [12] P. Ewels, M. Magnusson, S. Lundin, and M. Käller, “MultiQC: Summarize analysis results for multiple tools and samples in a single report,” *Bioinformatics*, vol. 32, no. 19, pp. 3047–3048, 2016, doi: [10.1093/bioinformatics/btw354](https://doi.org/10.1093/bioinformatics/btw354).
- [13] N. Rohland, S. Mallick, M. Mah, R. Maier, N. Patterson, and D. Reich, “Three assays for in-solution enrichment of ancient human DNA at more than a million SNPs,” *Genome Research*, vol. 32, no. 11–12, pp. 2068–2078, 2022, doi: [10.1101/gr.276728.122](https://doi.org/10.1101/gr.276728.122).
- [14] R. Davidson, X. Rocarada, *et al.*, “Optimized in-solution enrichment of over a million ancient human SNPs,” *Genome Biology*, vol. 26, no. 1, 2025, doi: [10.1186/s13059-025-03622-6](https://doi.org/10.1186/s13059-025-03622-6).
- [15] N. Rohland, I. Glocke, A. Aximu-Petri, and M. Meyer, “Extraction of highly degraded DNA from ancient bones, teeth and sediments for high-throughput sequencing,” *Nature Protocols*, vol. 13, no. 11, pp. 2447–2461, 2018, doi: [10.1038/s41596-018-0050-5](https://doi.org/10.1038/s41596-018-0050-5).
- [16] M. L. Carpenter *et al.*, “Pulling out the 1,” *The American Journal of Human Genetics*, vol. 93, no. 5, pp. 852–864, 2013, doi: [10.1016/j.ajhg.2013.10.002](https://doi.org/10.1016/j.ajhg.2013.10.002).
- [17] C. J. Adler *et al.*, “Sequencing ancient calcified dental plaque shows changes in oral microbiota with dietary shifts of the neolithic and industrial revolutions,” *Nature Genetics*, vol. 45, no. 4, pp. 450–455, 2013, doi: [10.1038/ng.2536](https://doi.org/10.1038/ng.2536).
- [18] I. Lazaridis and et al., “The genetic history of the southern arc: A bridge between west asia and europe,” *Science*, vol. 377, no. 6609, p. eabm4247, 2022, doi: [10.1126/science.abm4247](https://doi.org/10.1126/science.abm4247).
- [19] A. Mitnik and et al., “Kinship-based social inequality in bronze age europe,” *Science*, vol. 366, no. 6466, pp. 731–734, 2019, doi: [10.1126/science.aax6219](https://doi.org/10.1126/science.aax6219).
- [20] I. Mathieson and et al., “Genome-wide patterns of selection in 230 ancient eurasians,” *Nature*, vol. 528, no. 7583, pp. 499–503, 2015, doi: [10.1038/nature16152](https://doi.org/10.1038/nature16152).
- [21] S. Horvath, “DNA methylation age of human tissues and cell types,” *Genome Biology*, vol. 14, no. 10, p. R115, 2013, doi: [10.1186/gb-2013-14-10-r115](https://doi.org/10.1186/gb-2013-14-10-r115).
- [22] V. M. Narasimhan and et al., “Epigenetic clocks for ancient humans,” *Nature Ecology & Evolution*, vol. 7, 2023, doi: [10.1038/s41559-023-02116-2](https://doi.org/10.1038/s41559-023-02116-2).
- [23] H. Li and R. Durbin, “Fast and accurate short read alignment with burrows-wheeler transform,” *Bioinformatics*, vol. 25, no. 14, pp. 1754–1760, 2009, doi: [10.1093/bioinformatics/btp324](https://doi.org/10.1093/bioinformatics/btp324).
- [24] M. Meyer *et al.*, “A high-coverage genome sequence from an archaic denisovan individual,” *Science*, vol. 338, no. 6104, pp. 222–226, 2012, doi: [10.1126/science.1224344](https://doi.org/10.1126/science.1224344).
- [25] M. Schubert *et al.*, “Improving ancient DNA read mapping against modern reference genomes,” *BMC Genomics*, vol. 13, p. 178, 2012, doi: [10.1186/1471-2164-13-178](https://doi.org/10.1186/1471-2164-13-178).
- [26] H. Renaud G., “Gargammel: A sequence simulator for ancient DNA,” *Bioinformatics*, pp. 577–579, 2017.

- [27] Genome Reference Consortium, “Human genome reference assemblies.” 2026. Available: <https://www.ncbi.nlm.nih.gov/grc/human>
- [28] H. Feng, K. N. Conneely, and H. Wu, “A bayesian hierarchical model to detect differentially methylated loci from single nucleotide resolution sequencing data,” *Nucleic Acids Research*, vol. 42, no. 8, p. e69, 2014, doi: [10.1093/nar/gku154](https://doi.org/10.1093/nar/gku154).
- [29] M. D. Young, M. J. Wakefield, G. K. Smyth, and A. Oshlack, “Gene ontology analysis for RNA-seq: Accounting for selection bias,” *Genome Biology*, vol. 11, no. 2, p. R14, 2010, doi: [10.1186/gb-2010-11-2-r14](https://doi.org/10.1186/gb-2010-11-2-r14).